UNIVERSIDADE FEDERAL DO PIAUÍ
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

Disciplina: Aprendizado de Máquina

Predição de Doença Cardíaca com Random Forest: comparação com a Árvore de Decisão

Integrantes:
Arthur Fernando Elvas Bohn (20261001997)
Diego Cordeiro de Oliveira (20261002180)
Keoma de Sousa Coelho (20261004952)

Professor: Dr. Vinicius Ponte Machado

Teresina, 30 de outubro de 2026

Disciplina: Aprendizado de Máquina — PPGCC/UFPI

Professor: Doutor Vinicius Ponte Machado

Data: 30/10/2026

Integrantes:

Integrante	Matrícula
Arthur Fernando Elvas Bohn	20261001997
Diego Cordeiro de Oliveira	20261002180
Keoma de Sousa Coelho	20261004952

Base: Heart Failure Prediction — Kaggle

Notebook: `docs/handle_forest/Random_Forest_Heart_Failure_mlflow.ipynb`

Referência de comparação: `Arvore_Decisao_Heart_Failure_mlflow.ipynb` (experimento `heart_failure_arvore_decisao`)

Lista de siglas e abreviaturas

Sigla	Significado
BP	Pressão arterial (*Blood Pressure*)
CV	Validação cruzada (*Cross-Validation*)
DAC	Doença arterial coronariana
ECG	Eletrocardiograma
F1	Média harmônica entre precisão e revocação
FC	Frequência cardíaca
FN	Falso negativo
FP	Falso positivo
HR	Frequência cardíaca (*Heart Rate*)
IC 95%	Intervalo de confiança de 95%
LVH	Hipertrofia ventricular esquerda (*Left Ventricular Hypertrophy*)
M/F	Masculino/feminino
MLflow	Plataforma de rastreamento de experimentos de aprendizado de máquina
OOB	*Out-of-bag* (amostras não sorteadas no bootstrap de cada árvore)
PCA	Análise de Componentes Principais (*Principal Component Analysis*)
PPGCC/UFPI	Programa de Pós-Graduação em Ciência da Computação da Universidade

Sigla	Significado
	Federal do Piauí
Prec. / Rec.	Precisão / revocação (*recall*)
RF	Random Forest (floresta aleatória)
SHAP	*SHapley Additive exPlanations*
SMOTE	*Synthetic Minority Over-sampling Technique* (sobreamostragem sintética)
SQLite	Banco de dados relacional leve
ST	Segmento ST do eletrocardiograma
TA/ATA/NAP/ASY	Angina típica / angina atípica / dor não anginosa / assintomático
TN / TP	Verdadeiro negativo / verdadeiro positivo
UCI	*University of California, Irvine* (repositório de conjuntos de dados)
Y/N	Sim/não

1. Introdução e problema

As doenças cardiovasculares estão entre as principais causas de morte no mundo. Um modelo de triagem que identifique pacientes com maior probabilidade de doença cardíaca pode apoiar a priorização de exames e reduzir o tempo até o tratamento. O problema é uma **classificação binária**:

- **Classe 1:** paciente com doença cardíaca (`HeartDisease = 1`);
- **Classe 0:** paciente sem doença (`HeartDisease = 0`).

O erro de maior gravidade clínica é o **falso negativo da classe 1**: classificar um paciente doente como "não doente". Por isso, além da acurácia, este trabalho dá atenção especial ao **recall e ao F1 da classe 1** (e ao F1 macro, que equilibra as duas classes).

Objetivo: repetir com **Random Forest** exatamente as estratégias já aplicadas à **Árvore de Decisão** — tratamento dos dados, busca em grade, ablação e engenharia de atributos — e **comparar as duas abordagens** de forma reprodutível, com todos os experimentos registrados no **MLflow**.

Por que a comparação é justa: as duas abordagens usam o **mesmo split estratificado 80/20 (semente 42)**, a **mesma validação cruzada** (`RepeatedStratifiedKFold`, 5 folds × 2

repetições), a **mesma grade** (864 combinações por codificação) e as **mesmas métricas**. A única diferença é o estimador: uma árvore única (`DecisionTreeClassifier`) contra uma floresta de 300 árvores (`RandomForestClassifier`).

---

2. Base de dados

2.1 Origem e descrição

A base é a **Heart Failure Prediction** (Kaggle, fedesoriano), derivada do **UCI Heart Disease** (Detrano et al., 1989), combinando cinco bases clínicas (Cleveland, Hungria, Suíça, Long Beach VA e Statlog). O arquivo `bases/heart.csv` contém **918 registros** e **12 colunas** (11 atributos + alvo). Como a base é a mesma da etapa da árvore, esta seção é resumida; o foco do documento está na comparação de resultados.

2.2 Dicionário de atributos

Atributo	Tipo	Descrição
`Age`	Numérico	Idade (anos)
`Sex`	Categórico	Sexo (M/F)
`ChestPainType`	Categórico	Tipo de dor no peito (TA, ATA, NAP, ASY)
`RestingBP`	Numérico	Pressão arterial em repouso (mm Hg)
`Cholesterol`	Numérico	Colesterol sérico (mm/dl)
`FastingBS`	Binário	Glicemia em jejum > 120 mg/dl (1/0)
`RestingECG`	Categórico	ECG em repouso (Normal, ST, LVH)
`MaxHR`	Numérico	Frequência cardíaca máxima atingida
`ExerciseAngina`	Categórico	Angina induzida por exercício (Y/N)
`Oldpeak`	Numérico	Depressão do segmento ST induzida por exercício
`ST_Slope`	Categórico	Inclinação do segmento ST no pico (Up/Flat/Down)
`HeartDisease`	Binário	Alvo: 1 = doença, 0 = normal

Legenda: `TA` = angina típica; `ATA` = angina atípica; `NAP` = dor não anginosa; `ASY` = assintomático; `M/F` = masculino/feminino; `Y/N` = sim/não; `ST` = segmento ST do eletrocardiograma; `LVH` = hipertrofia ventricular esquerda.

2.3 Distribuição e qualidade

Classe	Registros	Proporção
1 (com doença)	508	55,34%
0 (sem doença)	410	44,66%
Total	**918**	**100%**

- **Desbalanceamento leve:** a classe 1 é majoritária (55,34%).
- **Valores ausentes:** não há `NaN` original; porém `Cholesterol` tem **172 zeros** e `RestingBP` tem **1 zero**, fisiologicamente implausíveis. Esses zeros são convertidos em `NaN` e imputados **dentro do pipeline** (sem vazamento).
- **Duplicatas:** 0.
- **Split:** 80/20 estratificado → 734 treino e 184 teste (102 da classe 1 e 82 da classe 0 no teste).

2.4 Estatísticas descritivas

Variável	Média	Desvio	Mín.	Mediana	Máx.
Age	53,51	9,43	28,00	54,00	77,00
RestingBP	132,40	18,51	0,00	130,00	200,00
Cholesterol	198,80	109,38	0,00	223,00	603,00
FastingBS	0,23	0,42	0,00	0,00	1,00
MaxHR	136,81	25,46	60,00	138,00	202,00
Oldpeak	0,89	1,07	-2,60	0,60	6,20

3. Metodologia

3.1 Fluxo de processamento (pipeline)

O modelo é uma **floresta aleatória** (`RandomForestClassifier`) dentro de um fluxo de processamento (`Pipeline`) idêntico ao da árvore:

1. **Pré-processamento numérico:** `SimpleImputer` (estratégia testada: mediana, média, moda) + `StandardScaler`;
2. **Pré-processamento categórico:** `OneHotEncoder` ou `OrdinalEncoder` (comparados);
3. **Modelo:** `RandomForestClassifier` com `n_estimators = 300`.

Tudo é ajustado **somente no treino de cada partição (fold)** da validação cruzada, evitando vazamento.

3.2 Validação e seleção

- Divisão estratificada 80/20 (semente 42); o conjunto de teste é reservado até o fim.
- `RepeatedStratifiedKFold(5 folds × 2 repetições)` para a busca.
- `GridSearchCV` com métrica de reajuste (refit) **F1 da classe 1**; acurácia, precisão e recall também são medidos.
- Grade: imputação (3) × `criterion` (2) × `max_depth` (4) × `min_samples_split` (3) × `min_samples_leaf` (3) × `max_features` (2) × `class_weight` (2) = **864 combinações** por codificação; 8.640 ajustes por codificação; **17.280 ajustes** no total (one-hot + ordinal).

Valores testados em cada hiperparâmetro:

Parâmetro	Valores testados
`prep__num__imp__strategy`	`median`, `mean`, `most_frequent`
`modelo__criterion`	`gini`, `entropy`
`modelo__max_depth`	`3`, `5`, `7`, `None`
`modelo__min_samples_split`	`2`, `5`, `10`
`modelo__min_samples_leaf`	`1`, `3`, `5`
`modelo__max_features`	`None`, `sqrt`
`modelo__class_weight`	`None`, `balanced`
`modelo__n_estimators`	`300` (fixo na busca; avaliado à parte em 100, 300, 500 e 800)

- Avaliação no teste: acurácia, precisão, recall e F1 para **as duas classes**, F1 macro, IC 95% do F1 da classe 1 (bootstrap com 1.000 reamostragens), matriz de confusão e contagem de FN/FP.

3.3 Fases do notebook

Fase	O que faz
1. Configuração	Semente, MLflow (SQLite compartilhado), pastas `docs/handle_forest/...`
2. Carga/limpeza	Lê `bases/heart.csv`; zeros de `Cholesterol`/`RestingBP` → `NaN`
3. Preparação	`ColumnTransformer` (imputação + encoding + scaler), split 80/20, CV 5×2

Fase	O que faz
4. Grid search	864 combinações por codificação; one-hot e ordinal; OOB score; log no MLflow
5. Avaliação	Métricas das duas classes, IC 95%, matriz de confusão, FN/FP, importâncias
6. Baseline	`DummyClassifier(most_frequent)` como referência
7. Interpretação	Importância média e dispersão entre árvores, árvore representativa, permutação, invariância à escala
8. Ablação	Remove 1 atributo por vez; mesmos hiperparâmetros; ambas as classes
9. Engenharia	5 razões/interações clínicas; comparação sem/com
10. Nº de árvores	100, 300, 500 e 800 árvores com os melhores parâmetros
11. Comparação	Tabelas e gráfico RF × árvore; deltas registrados no MLflow
12. Exportação	CSVs, JSON, PNGs e ZIP; artefatos no MLflow
13. Consulta	Exportação das runs dos dois experimentos para CSV

3.4 Engenharia de atributos testada

Atributo derivado	Fórmula	Motivação
`FC_pct_teorica`	`MaxHR / (220 − Age)`	% da FC máxima teórica
`Chol_por_Idade`	`Cholesterol / Age`	colesterol relativo à idade
`BP_por_Idade`	`RestingBP / Age`	pressão relativa à idade
`Oldpeak_por_FC`	`Oldpeak / MaxHR`	depressão ST por batimento
`Angina_x_Oldpeak`	`(ExerciseAngina == 'Y') × Oldpeak`	interação angina × ST

As razões são calculadas **linha a linha**, antes da divisão (split), sem vazamento.

3.5 Recursos específicos do Random Forest

- **OOB score:** cada árvore é treinada em uma amostra bootstrap; as observações deixadas de fora funcionam como validação interna. O OOB é registrado como métrica adicional (não participa da seleção, para manter o critério igual ao da árvore).
- **Dispersão das importâncias:** a importância é calculada em cada uma das 300 árvores; reporta-se média, desvio e quartis. Uma variável com importância alta mas muito instável entre árvores é menos confiável.
- **Importância por permutação:** mede a queda de F1 no teste ao embaralhar cada atributo original — complementa a importância por impureza, que é enviesada para variáveis com muitos valores distintos.

- **Sensibilidade ao número de árvores:** 100, 300, 500 e 800 árvores com os melhores hiperparâmetros, para verificar o retorno decrescente.

---

4. Resultados do Random Forest

4.1 Busca em grade e hiperparâmetros selecionados

Codificação	Imputação	class_weight	criterion	max_depth	max_features	min_samples_leaf	min_samples_split	n_estimators	OOB	Tempo (min)
onehot	median	balanced	entropy	None	sqrt	5	2	300	0,8583	12,0
ordinal	mean	balanced	entropy	7	sqrt	1	5	300	0,8583	14,4

A busca avaliou **864 combinações por codificação** (17.280 ajustes no total), com F1 da classe 1 como critério. As duas codificações convergiram para `criterion='entropy'`, `max_features='sqrt'` e `class_weight='balanced'`; a diferença está na profundidade (one-hot sem limite, ordinal 7), no tamanho mínimo de folha e na imputação (mediana × média). Na prática, as árvores ficaram com profundidade média de **9,9** (one-hot) e **7,0** (ordinal), com cerca de 44 e 50 folhas por árvore.

Os **tempos de busca** foram de **12,0 min** (one-hot) e **14,4 min** (ordinal) — muito acima do custo da árvore única, que leva poucos segundos, pois cada ajuste treina 300 árvores.

4.2 Comparação entre codificações one-hot e ordinal no conjunto de teste

Codificação	Acurácia	Prec_c0	Rec_c0	F1_c0	Prec_c1	Rec_c1	F1_c1	F1_macro	IC95 F1_c1
ordinal	0,8859	0,8588	0,8902	0,8743	0,9091	0,8824	0,8955	0,8849	0,8469–0,9368
onehot	0,8804	0,8750	0,8537	0,8642	0,8846	0,9020	0,8932	0,8787	0,8442–0,9347

Interpretação: a codificação **ordinal** obteve o maior **F1_c1 (0,8955)**, a maior acurácia (0,8859) e a maior precisão da classe 1 (0,9091), com **12 falsos negativos**; a **one-hot** teve maior recall da classe 1 (0,9020) e F1_c0 (0,8642), com **10 FN**. Os intervalos de confiança do F1_c1 se sobrepõem quase totalmente, então a diferença entre as codificações **não é conclusiva**.

Ponto de atenção metodológico: o melhor F1 na **validação cruzada** foi o da codificação **onehot** (0,8809), enquanto o melhor F1 no **teste** foi o da **ordinal** (0,8955). É o mesmo padrão observado na árvore: a CV e o teste de 184 pacientes discordam em detalhes finos.

4.3 Referência (baseline) da classe majoritária

O classificador ingênuo (`DummyClassifier`, estratégia `most_frequent`) prediz sempre a classe 1:

Métrica	Valor
Acurácia	0,5543
Precisão_c1	0,5543
Recall_c1	1,0000
F1_c1	0,7133
F1_c0	0,0000
F1_macro	0,3566

A referência tem **0 falsos negativos** (recall da classe 1 = 1), mas **82 falsos positivos**: todo paciente sadio é classificado como doente. O Random Forest supera a referência com folga no F1_c1 (0,8955 contra 0,7133) e reduz esse custo a **9 falsos positivos**.

4.4 Ablação de atributos (seleção de variáveis)

Cada atributo foi removido individualmente, mantendo os melhores hiperparâmetros e `class_weight=None` (mesmo procedimento da árvore).

Cenário	Atributo removido	Acurácia	F1_c0	F1_c1	F1_macro	FN	F1_CV
todos	nenhum	0,8967	0,8805	0,9091	0,8948	7	0,8744
sem_MaxHR	MaxHR	0,8859	0,8662	0,9005	0,8834	7	0,8797
sem_Oldpeak	Oldpeak	0,8859	0,8662	0,9005	0,8834	7	0,8722
sem_Cholesterol	Cholesterol	0,8859	0,8696	0,8986	0,8841	9	0,8742
sem_FastingBS	FastingBS	0,8859	0,8696	0,8986	0,8841	9	0,8750
sem_Age	Age	0,8804	0,8608	0,8952	0,8780	8	0,8740
sem_RestingBP	RestingBP	0,8750	0,8553	0,8900	0,8726	9	0,8716
sem_RestingECG	RestingECG	0,8696	0,8519	0,8835	0,8677	11	0,8767
sem_Sex	Sex	0,8641	0,8428	0,8804	0,8616	10	0,8689
sem_ExerciseAngina	ExerciseAngina	0,8478	0,8293	0,8627	0,8460	14	0,8752

Cenário	Atributo removido	Acurácia	F1_c0	F1_c1	F1_macro	FN	F1_CV
sem_ST_Slope	ST_Slope	0,8478	0,8333	0,8600	0,8467	16	0,8303
sem_ChestPainType	ChestPainType	0,8261	0,8095	0,8400	0,8248	18	0,8737

Interpretação:

- O conjunto completo (`todos`) tem o **maior F1_c1 (0,9091)** e o **menor número de falsos negativos (7)**: nenhuma remoção melhora a métrica principal.
- Remover `MaxHR` ou `Oldpeak` mantém o recall (FN = 7), mas reduz a precisão e o F1_c1 para 0,9005; remover `Cholesterol` ou `FastingBS` leva a 9 FN.
- As remoções mais danosas são `ChestPainType` (F1_c1 0,8400, 18 FN), `ST_Slope` (0,8600, 16 FN) e `ExerciseAngina` (0,8627).
- Conclusão: **manter todos os atributos** para maximizar o F1_c1 — a mesma conclusão obtida com a árvore.

4.5 Engenharia de atributos (razões e interações clínicas)

Cenário	Nº atributos	Acurácia	F1_c0	F1_c1	F1_macro	FN	FP	F1_CV
sem_engenharia	11	0,8967	0,8805	0,9091	0,8948	7	12	0,8744
com_engenharia	16	0,8370	0,8125	0,8558	0,8341	13	17	0,8775

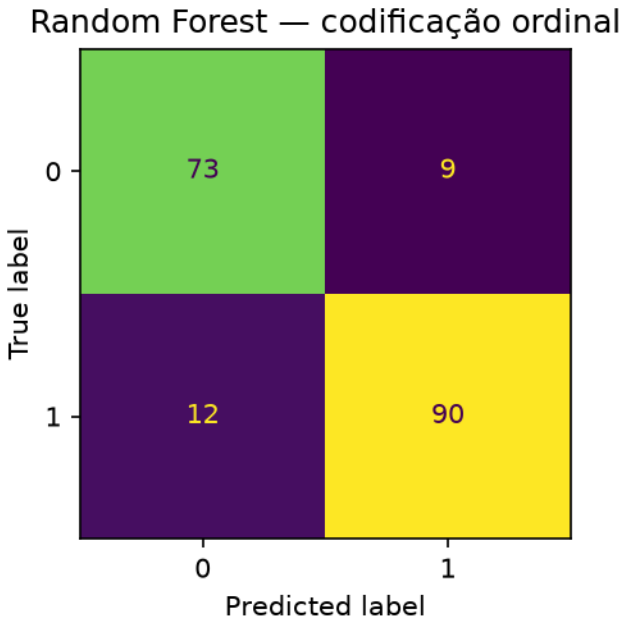
Efeito no teste: as 5 features derivadas **pioraram** o resultado — F1_c1 0,9091 → 0,8558 (-0,0533), recall_c1 0,9314 → 0,8725 e falsos negativos 7 → 13. Na validação cruzada houve ligeira **melhora** (0,8744 → 0,8775), mas sem confirmação no teste.

Comparação com a árvore: o efeito foi **oposto**. Na árvore, a engenharia melhorou o teste (0,8387 → 0,8545) e piorou a CV (0,8604 → 0,7946); na floresta, piorou o teste e manteve a CV estável. Isso é coerente com a hipótese de que o ensemble já representa interações por meio da combinação de cortes, tornando as razões redundantes (e, com 5 atributos a mais em 734 registros, aumentando a variância).

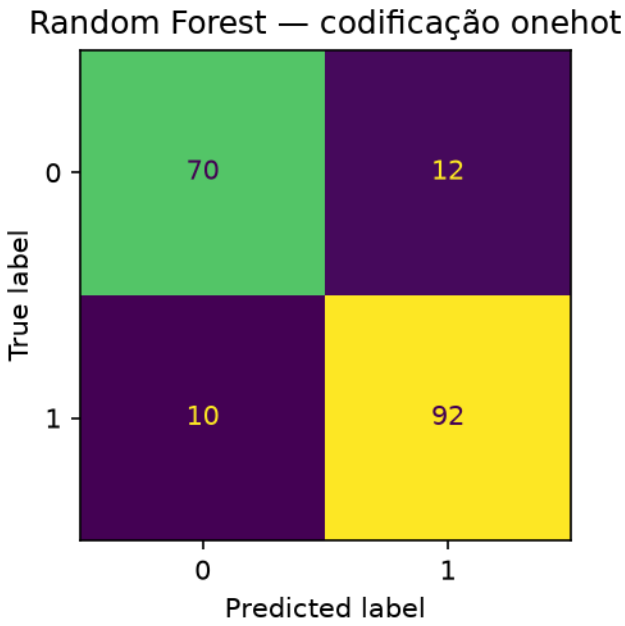
4.6 Matrizes de confusão e o erro de maior gravidade clínica

Com o teste de 184 pacientes (82 da classe 0 e 102 da classe 1):

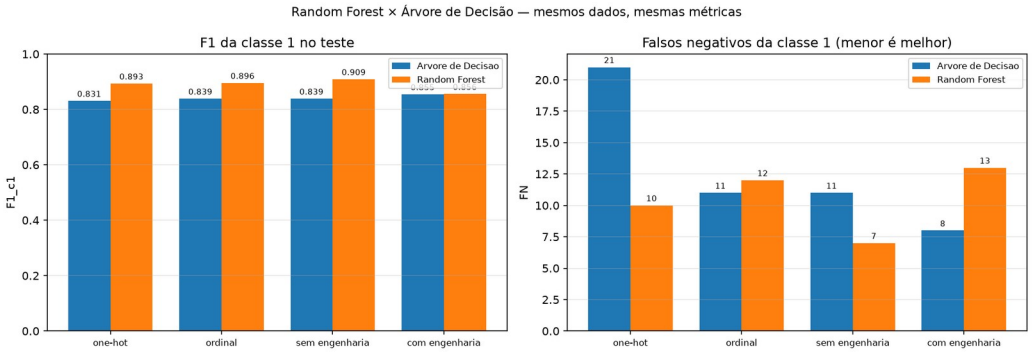
Modelo	TN	FP	FN (classe 1)	TP	Recall_c1	F1_c1	F1_CV
RF sem_engenharia	70	12	7	95	0,9314	0,9091	0,8744
RF ordinal	73	9	12	90	0,8824	0,8955	0,8799
RF one-hot	70	12	10	92	0,9020	0,8932	0,8809
Árvore com_engenharia	58	24	8	94	0,9216	0,8545	—
Árvore ordinal	58	24	11	91	0,8922	0,8387	0,8604
Árvore one-hot	70	12	21	81	0,7941	0,8308	0,8550
Baseline (classe majoritária)	0	82	0	102	1,0000	0,7133	—



Matriz de confusão — Random Forest (ordinal)



Matriz de confusão — Random Forest (one-hot)

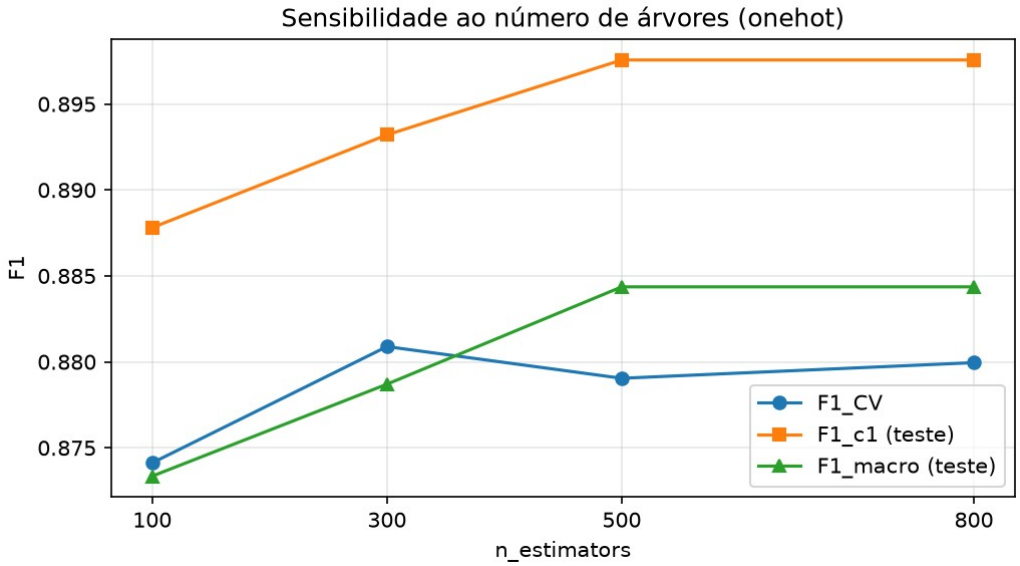


Comparação RF × Árvore de Decisão

O erro de maior gravidade clínica: o **falso negativo da classe 1**. A melhor configuração da floresta (`sem_engenharia`, isto é, todos os 11 atributos, one-hot e `class_weight=None`) produz **7 falsos negativos** — melhor que os **8 da árvore com engenharia** — mantendo 12 falsos positivos contra 24 da árvore. A configuração escolhida pela busca (ordinal, `class_weight='balanced'`) tem 12 FN e apenas 9 FP: menos alarmes falsos, porém mais doentes sem diagnóstico.

4.7 Sensibilidade ao número de árvores

Nº de árvores	F1_CV	Acurácia	F1_c1	F1_macro	FN	FP	IC95 F1_c1
100	0,8741	0,8750	0,8878	0,8734	11	12	0,8374–0,9302
300	0,8809	0,8804	0,8932	0,8787	10	12	0,8442–0,9347
500	0,8790	0,8859	0,8976	0,8844	10	11	0,8500–0,9390
800	0,8800	0,8859	0,8976	0,8844	10	11	0,8479–0,9372



Sensibilidade ao número de árvores

O ganho é **decrescente**: de 100 para 300 árvores o F1_c1 sobe 0,0054 (FN de 11 para 10); de 300 para 500 sobe apenas 0,0044; e 500 e 800 árvores produzem as **mesmas métricas** no teste (F1_c1 0,8976, 10 FN e 11 FP). O F1_CV praticamente não muda (0,8741–0,8809). Portanto, **300 árvores** é um bom compromisso entre custo e estabilidade, e o OOB score de **0,8583** (630 dos 734 registros de treino classificados corretamente fora do bootstrap, o mesmo valor nas duas codificações) confirma que a floresta generaliza de forma consistente.

4.8 Importância das variáveis

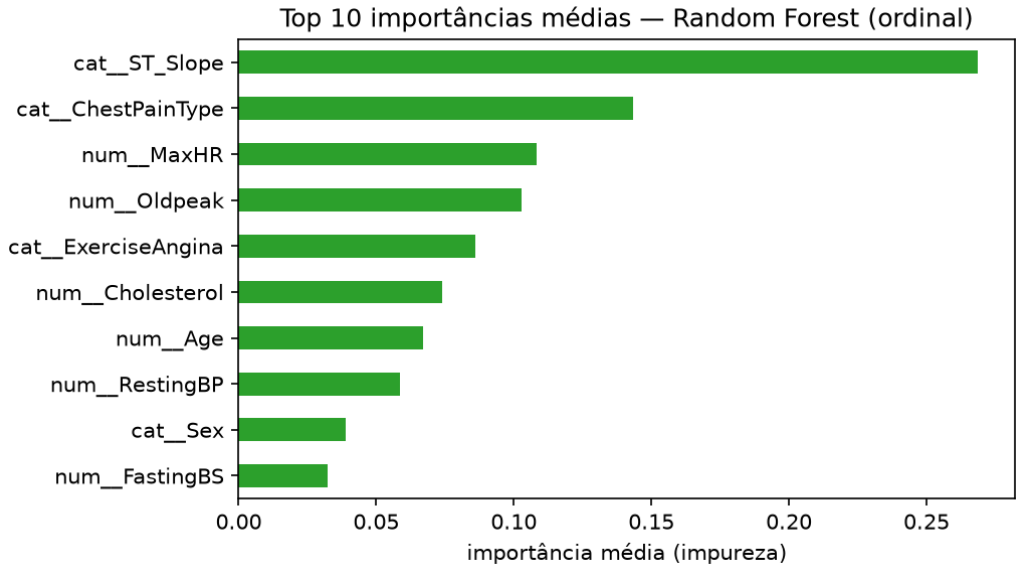
Importância média por impureza na codificação **ordinal** (média de 300 árvores):

Variável	Importância média	Desvio entre árvores	p25	p75
cat__ST_Slope	0,2687	0,1328	0,1608	0,4103
cat__ChestPainType	0,1432	0,0913	0,0760	0,1926

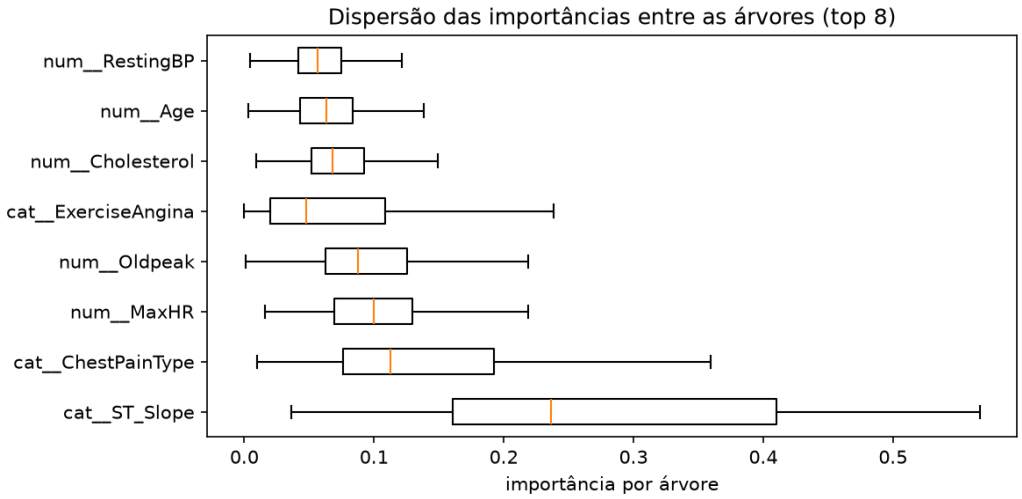
Variável	Importância média	Desvio entre árvores	p25	p75
num__MaxHR	0,1083	0,0539	0,0693	0,1296
num__Oldpeak	0,1030	0,0602	0,0629	0,1257
cat__ExerciseAngina	0,0860	0,0916	0,0199	0,1082
num__Cholesterol	0,0739	0,0328	0,0517	0,0925
num__Age	0,0669	0,0316	0,0429	0,0835
num__RestingBP	0,0585	0,0227	0,0418	0,0747
cat__Sex	0,0388	0,0227	0,0225	0,0527
num__FastingBS	0,0323	0,0254	0,0128	0,0478

Importância por **permutação** no teste (queda de F1 ao embaralhar o atributo original):

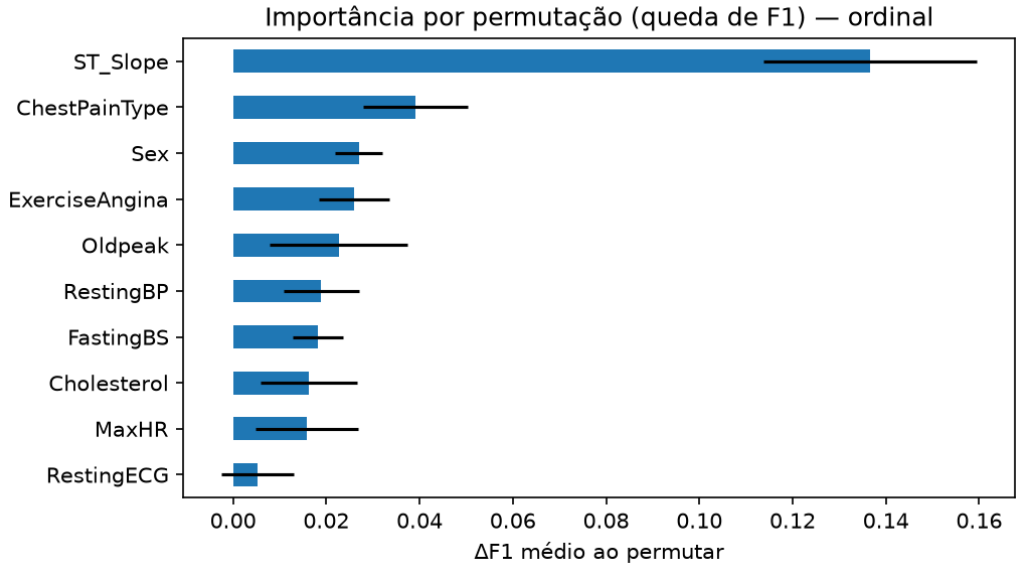
Variável	ΔF1 médio	Desvio
ST_Slope	0,1367	0,0229
ChestPainType	0,0391	0,0112
Sex	0,0269	0,0051
ExerciseAngina	0,0259	0,0076
Oldpeak	0,0226	0,0149
RestingBP	0,0189	0,0081
FastingBS	0,0182	0,0054
Cholesterol	0,0163	0,0104



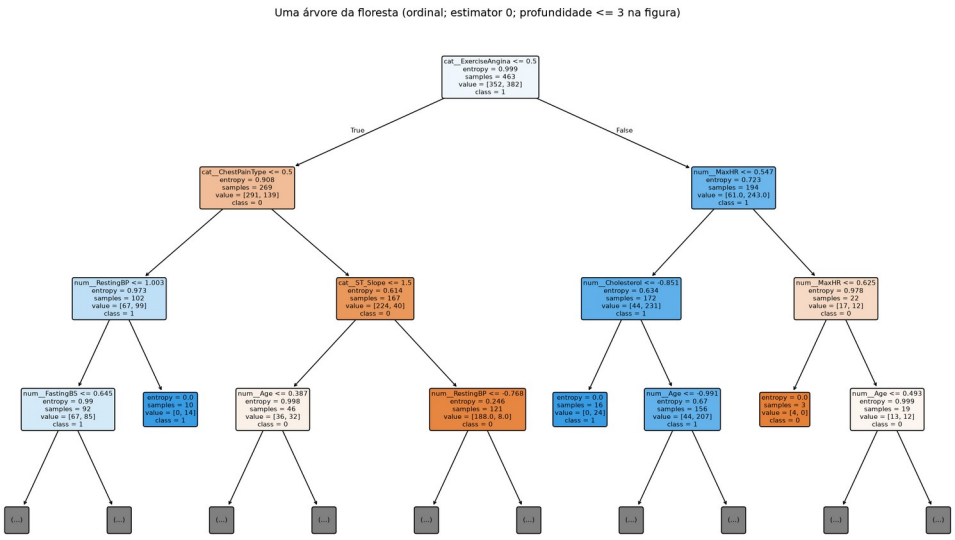
Top 10 importâncias médias (Random Forest)



Dispersão das importâncias entre as árvores



Importância por permutação



Uma árvore representativa da floresta

Leitura: `ST_Slope` é a variável dominante nas duas medidas (importância 0,2687 por impureza e ΔF1 0,1367 na permutação), seguida por `ChestPainType`, `MaxHR` e `Oldpeak`. A dispersão é alta para `ST_Slope` (desvio 0,1328), o que é esperado em uma variável categórica com três níveis: em algumas árvores ela concentra quase toda a decisão, em outras é secundária. Na codificação one-hot, a atenção se divide entre `ST_Slope_Up` (0,2001) e `ST_Slope_Flat` (0,1108) — a soma dos dois níveis é comparável à importância do atributo único na versão ordinal, um efeito conhecido do one-hot.

Contraste com a árvore: a árvore escolhida (ordinal) usava `ExerciseAngina` e `ST_Slope` na raiz e deixava `ChestPainType` em terceiro lugar; a floresta distribui a decisão entre centenas de árvores, e `ChestPainType` sobe para a segunda posição. A interpretação deixa de ser "um caminho de decisão" e passa a ser "quais variáveis reduzem impureza com mais frequência".

---

5. Comparação Random Forest × Árvore de Decisão

5.1 Visão geral

Cenário	F1_c1 árvore	F1_c1 RF	ΔF1_c1	FN árvore	FN RF	F1_macro árvore	F1_macro RF
one-hot	0,8308	0,8932	0,0624	21	10	0,8200	0,8787
ordinal	0,8387	0,8955	0,0568	11	12	0,8035	0,8849

Cenário	F1_c1 árvore	F1_c1 RF	ΔF1_c1	FN árvore	FN RF	F1_macro árvore	F1_macro RF
sem engenharia	0,8387	0,9091	0,0704	11	7	0,8035	0,8948
com engenharia	0,8545	0,8558	0,0012	8	13	0,8192	0,8341

A floresta foi superior em todos os cenários comparáveis, tanto em F1 da classe 1 (Δ de **0,0012** a **0,0704**) quanto em F1 macro, com **menos falsos negativos em dois dos quatro cenários** (one-hot: 10 contra 21; sem engenharia: 7 contra 11) e **menos falsos positivos em três deles** (ordinal: 9 contra 24; sem engenharia: 12 contra 24; com engenharia: 17 contra 24), com empate no one-hot (12 contra 12).

Os destaques:

- **Melhor resultado no teste:** floresta com **todos os atributos** (one-hot, `class_weight=None`): F1_c1 **0,9091**, 7 FN e 12 FP — contra **0,8545**, 8 FN e 24 FP da melhor árvore (`com_engenharia`).
- **Modelo escolhido pela busca (CV):** floresta one-hot com `class_weight='balanced'`: F1_CV **0,8809**, F1_c1 **0,8932**, 10 FN — ainda acima da melhor árvore no teste e com o melhor F1_CV das duas abordagens (0,8604 na árvore).
- **A árvore tem um ponto forte relativo:** o melhor F1_c1 da árvore (0,8545) usa engenharia de atributos e chega a 8 FN, próximo dos 7 FN da melhor floresta — porém com **o dobro de falsos positivos** (24 contra 12) e F1_macro inferior (0,8192 contra 0,8948).

5.2 Validação cruzada × teste

Modelo	Cenário	F1_CV	F1_c1 (teste)	Teste − CV
Árvore	onehot	0,8550	0,8308	-0,0242
Árvore	ordinal	0,8604	0,8387	-0,0217
Random Forest	onehot	0,8809	0,8932	0,0123
Random Forest	ordinal	0,8799	0,8955	0,0156
Árvore	sem_engenharia	0,8604	0,8387	-0,0217
Árvore	com_engenharia	0,7946	0,8545	0,0599
Random Forest	sem_engenharia	0,8744	0,9091	0,0347
Random Forest	com_engenharia	0,8775	0,8558	-0,0217

A tabela evidencia dois pontos:

1. **A floresta tem F1_CV maior** que a árvore em todas as configurações: 0,8809 e 0,8799 contra 0,8604 e 0,8550. O ganho não aparece só no teste reservado: ele é consistente na validação repetida.
2. **O teste é otimista para a floresta sem `class_weight`** (`sem_engenharia`: F1_CV 0,8744 → teste 0,9091), enquanto para a configuração escolhida pela busca o teste fica próximo da CV (0,8799 → 0,8955). Com 184 pacientes no teste, diferenças dessa ordem (0,03) estão dentro do ruído amostral — os IC 95% deixam isso explícito.

5.3 Intervalos de confiança de 95% (F1 da classe 1)

Modelo / cenário	F1_c1	IC 95%
Random Forest ordinal	0,8955	0,8469–0,9368
Random Forest one-hot	0,8932	0,8442–0,9347
Árvore ordinal	0,8387	0,7817–0,8879
Árvore one-hot	0,8308	0,7650–0,8865

Os intervalos da floresta e da árvore **se sobrepõem parcialmente** (por exemplo, floresta ordinal 0,8469–0,9368 e árvore ordinal 0,7817–0,8879), de modo que a superioridade da floresta **não pode ser declarada estatisticamente conclusiva** com este tamanho de teste. A conclusão defensável é: a floresta é **consistentemente melhor ou igual**, com vantagem clara em F1_CV, F1_macro e no número de falsos positivos, mas o intervalo ainda admite empate.

5.4 Ablação comparada

Cenário	F1_c1 árvore	F1_c1 RF	ΔF1_c1	F1_macro árvore	F1_macro RF	ΔF1_macro
sem_Oldpeak	0,7647	0,9005	0,1358	0,7360	0,8834	0,1473
sem_RestingECG	0,7647	0,8835	0,1188	0,7360	0,8677	0,1317
sem_Sex	0,7647	0,8804	0,1157	0,7360	0,8616	0,1256
sem_MaxHR	0,7890	0,9005	0,1115	0,7412	0,8834	0,1422
sem_ChestPainType	0,7647	0,8400	0,0753	0,7360	0,8248	0,0888
sem_Age	0,8229	0,8952	0,0723	0,8149	0,8780	0,0631
sem_Cholesterol	0,8272	0,8986	0,0713	0,8204	0,8841	0,0637
sem_FastingBS	0,8272	0,8986	0,0713	0,8204	0,8841	0,0637
todos	0,8387	0,9091	0,0704	0,8035	0,8948	0,0913
sem_ST_Slope	0,7897	0,8600	0,0703	0,7764	0,8467	0,0703
sem_RestingBP	0,8272	0,8900	0,0627	0,8204	0,8726	0,0523

Cenário	F1_c1 árvore	F1_c1 RF	ΔF1_c1	F1_macro árvore	F1_macro RF	ΔF1_macro
sem_ExerciseAngina	0,8042	0,8627	0,0585	0,7988	0,8460	0,0472

A floresta venceu em todos os 12 cenários de ablação, com ΔF1_c1 entre 0,0585 e 0,1358. Dois padrões merecem atenção:

- **A árvore é muito mais sensível à remoção de atributos.** Remover `Oldpeak`, `RestingECG`, `Sex` ou `ChestPainType` derruba o F1_c1 da árvore para 0,7647 (Δ de até 0,1358), enquanto a floresta se mantém entre 0,8400 e 0,9091. Isso é a contrapartida prática da **redução de variância**: o ensemble compensa a ausência de uma variável distribuindo a decisão entre as demais.
- **A ordenação das variáveis relevantes é parecida**: em ambas, `ST_Slope` e `ChestPainType` são as remoções mais custosas (na floresta, F1_c1 cai para 0,8600 e 0,8400), coerente com a importância das variáveis.

5.5 Leitura crítica: por que a floresta ganha e o que isso custa

Ganho (redução de variância). Uma árvore única é um estimador de **alta variância**: pequenas mudanças no treino produzem árvores diferentes, e a árvore escolhida tem profundidade 3 (poucos cortes, muito viés) justamente porque profundidades maiores não generalizavam. A floresta troca esse compromisso: mantém árvores profundas (profundidade média de 7 a 10) e **média** centenas de predições, o que reduz a variância sem aumentar o viés. O resultado observado — F1_CV de 0,8604 (árvore) para 0,8809 (floresta) e F1_c1 no teste de 0,8545 para 0,9091 — é exatamente o esperado teoricamente.

Custo computacional. A busca da floresta levou 26,5 minutos (864 combinações × 10 folds × 300 árvores, duas codificações) contra poucos segundos da árvore. Em contrapartida, a predição continua barata: uma floresta de 300 árvores é avaliada em milissegundos para centenas de pacientes.

Custo de interpretabilidade. A árvore entrega um caminho de decisão auditável (`ExerciseAngina` → `ST_Slope` → …), útil para explicar a um clínico. A floresta exige importância agregada, dispersão entre árvores e importância por permutação — três artefatos produzidos neste trabalho — e mesmo assim não oferece uma regra única. Para triagem, a

diferença de desempenho favorece a floresta; para explicabilidade regulatória, a árvore tem vantagem.

Engenharia de atributos. O resultado mais interessante da comparação: a engenharia **ajudou a árvore** (F1_c1 0,8387 → 0,8545) e **prejudicou a floresta** (0,9091 → 0,8558). A interpretação é direta: as razões existiam para dar à árvore única cortes "diagonais" que ela não consegue representar; a floresta já constrói essa fronteira combinando muitos cortes, e os atributos extras apenas adicionam ruído e diluem a seleção aleatória de variáveis por nó (`max_features='sqrt'`).

---

6. MLflow: registro e comparação dos experimentos

Todos os experimentos foram registrados no **mesmo banco SQLite** (`mlflow.db`) e no mesmo servidor de rastreamento local, em **dois experimentos**:

Experimento	Modelo	Runs registradas	Artefatos
`heart_failure_random_forest`	`RandomForestClassifier` (300 árvores)	26	modelo, matrizes de confusão, importâncias, CSVs, ZIP
`heart_failure_arvore_decisao`	`DecisionTreeClassifier`	111	modelo, matrizes de confusão, importâncias das variáveis, CSVs, ZIP

Runs do experimento da floresta:

Run	Conteúdo
`random_forest_onehot` / `random_forest_ordinal`	busca em grade (864 combinações), métricas de CV, OOB, modelo e variações
`baseline_classe_majoritaria`	`DummyClassifier(most_frequent)`
`ablacao_atributos` (+ 12 filhas)	remoção de um atributo por vez
`engenharia_features` (`sem_engenharia`, `com_engenharia`)	comparação com as 5 features derivadas
`sensibilidade_n_estimators` (+ `arvores_100`, `arvores_300`, `arvores_500`, `arvores_800`)	efeito do número de árvores
`comparacao_rf_vs_arvore`	deltas de F1_c1, F1_macro, recall e FN em relação à árvore, com as tabelas comparativas
`relatorio_artefatos`	todos os arquivos usados neste relatório

Como reproduzir e comparar:

```
mlflow ui --backend-store-uri sqlite:///mlflow.db
```

Na interface (http://127.0.0.1:5000), selecione os dois experimentos na aba *Compare* para visualizar, na mesma tabela, `f1_cv`, `f1_treino_cv`, `F1_c1`, `F1_macro`, `FN`, `tempo_busca_s` e `oob_score` (apenas na floresta). As tabelas completas de runs foram exportadas para `docs/handle_forest/mlflow_runs_random_forest.csv` e `docs/handle_forest/mlflow_runs_arvore_decisao.csv`.

---

7. Discussão e trabalhos relacionados

Trabalho	Contribuição	Relação com este trabalho
Breiman (2001)	Propõe o Random Forest: agregação por *bagging* + seleção aleatória de atributos	Fundamenta o modelo e a expectativa de redução de variância
Qadri et al. (2023), IEEE Access	Técnica de engenharia de atributos para predição de doença cardíaca	Justifica a criação de atributos derivados
Abass et al. (2025), Springer	Compara LR, SVM, KNN, DT e RF com engenharia de atributos	Reforça a engenharia como etapa e a comparação DT × RF
Gárate-Escamilla et al. (2020), Informatics in Medicine Unlocked	Seleção de atributos + PCA	Compara seleção/transformação
Hasnat et al. (2025), arXiv	Engenharia de atributos + SHAP + árvores substitutas	Interpretabilidade de ensembles
Fernández-Delgado et al. (2014), JMLR	Avaliação de 179 classificadores em 121 bases	Evidência de que RF é um dos métodos mais consistentes sem ajuste fino
Page et al. (1970), Circulation	Idade e colesterol total como preditores de DAC	Fundamenta idade e colesterol; a razão `Chol_por_Idade` é proposta deste trabalho
Folsom et al. (2003), Diabetes Care	Fatores de risco para DAC	Contexto clínico
Detrano et al. (1989) / Janosi et al. (1988)	Base UCI Heart Disease	Origem dos dados
Fox et al. (1971)	Fórmula `FCmax ≈ 220 − idade`	Base de `FC_pct_teorica`

Por que a floresta venceu. Breiman (2001) mostra que a média de árvores descorrelacionadas reduz a variância do erro sem aumentar o viés. Neste trabalho, isso se traduziu em três efeitos observáveis: (i) F1_CV maior; (ii) robustez à remoção de atributos na ablação; (iii) menos falsos positivos com o mesmo número de falsos negativos. O ganho, porém, não foi gratuito: a busca

em grade ficou cerca de duas ordens de grandeza mais cara e a interpretação exigiu três tipos de análise.

Sobre a engenharia de atributos. A literatura (Qadri et al., 2023; Abass et al., 2025) reporta ganhos com features derivadas em modelos simples, o que é compatível com o resultado da árvore. Já o efeito negativo na floresta é consistente com a ideia de que o ensemble já modela interações, e reforça a recomendação de **testar a engenharia por modelo**, em vez de assumi-la como ganho universal.

Limitações:

- Base pequena (918) e teste de 184 pacientes → intervalos de confiança largos e diferenças de 0,01–0,03 não conclusivas.
- Uma única semente de split; a CV é repetida (5×2), mas o teste é único.
- `n_estimators` foi fixado em 300 na busca (para igualar o orçamento da árvore); valores maiores foram avaliados apenas com os melhores parâmetros.
- Não foram testados ajuste de limiar de decisão, SMOTE, calibração de probabilidades, *stacking* ou validação externa.
- A comparação com a árvore usa a execução registrada na etapa anterior; pequenas diferenças de versão de biblioteca são possíveis, ainda que o protocolo seja idêntico.

---

8. Conclusão e recomendações

- **Melhor resultado no teste: Random Forest com todos os 11 atributos** (one-hot, `class_weight=None`), com **F1_c1 0,9091**, **7 falsos negativos**, 12 falsos positivos e F1_macro 0,8948.
- **Modelo mais robusto na CV: Random Forest one-hot** (`class_weight='balanced'`), com **F1_CV 0,8809** — melhor que a árvore (0,8604).
- **Comparação com a árvore:** a floresta foi superior em **todos os cenários** (ΔF1_c1 de 0,0585 a 0,1358 na ablação e de 0,0012 a 0,0704 nos cenários principais), com melhor F1_CV, melhor F1_macro e menos falsos positivos.

- **Engenharia de atributos:** ajudou a árvore e **prejudicou** a floresta → o ganho depende do modelo; não deve ser assumida como universal.
- **Ablação:** manter todos os atributos maximiza o F1_c1 nas duas abordagens; a floresta é bem menos sensível a remoções, o que é a assinatura prática da redução de variância.
- **Nº de árvores:** 300 já captura quase todo o ganho; 500 melhora marginalmente e 800 é idêntico a 500 no teste.
- **Recomendação clínica:** para triagem, a floresta é a escolha com melhor compromisso entre recall e precisão da classe 1; a árvore permanece útil quando a **explicabilidade do caminho de decisão** for requisito. Em ambos os casos, avaliar **ajuste de limiar** e validar em base externa antes de uso real.
- **MLflow:** os dois experimentos (26 runs na floresta e 111 na árvore) permitem reproduzir e comparar todos os experimentos em uma única interface.

---

9. Referências

1. BREIMAN, L. Random Forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: https://doi.org/10.1023/A:1010933404324.
2. FEDESORIANO. **Heart Failure Prediction Dataset**. Kaggle, 2021. Disponível em: https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction
3. DETRANO, R. et al. International application of a new probability algorithm for the diagnosis of coronary artery disease. **American Journal of Cardiology**, 1989.
4. JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. **Heart Disease**. UCI Machine Learning Repository, 1988.
5. QADRI, A. M. et al. Effective Feature Engineering Technique for Heart Disease Prediction With Machine Learning. **IEEE Access**, 2023.
6. ABASS, A.; BATHLA, G.; WASSON, V. Heart Disease Prediction Using Machine Learning with Feature Engineering. In: Soft Computing and Signal Processing (ICSCSP 2024). Lecture Notes in Networks and Systems, v. 1221. Springer, 2025, p. 697–709. DOI: https://doi.org/10.1007/978-981-96-0924-6_55.

7. GÁRATE-ESCAMILLA, A. K.; HAJJAM EL HASSANI, A.; ANDRÈS, E. Classification models for heart disease prediction using feature selection and PCA. **Informatics in Medicine Unlocked**, 2020.
8. HASNAT, M. A. et al. Interpretable Heart Disease Prediction via a Weighted Ensemble Model. **arXiv:2511.01947**, 2025.
9. FERNÁNDEZ-DELGADO, M.; CERNADAS, E.; BARRO, S.; AMORIM, D. Do we need hundreds of classifiers to solve real world classification problems? **Journal of Machine Learning Research**, v. 15, p. 3133–3181, 2014.
10. PAGE, I. H. et al. Prediction of Coronary Heart Disease Based on Clinical Suspicion, Age, Total Cholesterol, and Triglyceride. **Circulation**, v. 42, n. 4, p. 625–645, 1970. DOI: https://doi.org/10.1161/01.cir.42.4.625.
11. FOLSOM, A. R. et al. Prediction of Coronary Heart Disease in Middle-Aged Adults With Diabetes. **Diabetes Care**, 2003.
12. FOX, S. M.; NAUGHTON, J. P.; HASKELL, W. L. Physical activity and the prevention of coronary heart disease. **Annals of Clinical Research**, 1971.