Predição de Doença Cardíaca com Árvore de Decisão

- Predição de Doença Cardíaca com Árvore de Decisão: tratamento de dados, hiperparâmetros e engenharia de atributos
  - Lista de siglas e abreviaturas
  - 1. Introdução e problema
  - 2. Base de dados
  - 3. Metodologia
  - 4. Resultados
  - 5. MLflow: registro e tabulação dos experimentos
  - 6. Avaliação comparativa entre execuções
  - 7. Discussão e trabalhos relacionados
  - 8. Conclusão e recomendações
  - 9. Referências

Predição de Doença Cardíaca com Árvore de Decisão: tratamento de dados, hiperparâmetros e engenharia de atributos

Disciplina: Aprendizado de Máquina — PPGCC/UFPI
Professor: Doutor Vinicius Ponte Machado
Data: 26/10/2026

Integrantes:

Integrante	Matrícula
Arthur Fernando Elvas Bohn	20261001997
Diego Cordeiro de Oliveira	20261002180
Keoma de Sousa Coelho	20261004952

Base: Heart Failure Prediction — Kaggle
Notebook: `Arvore_Decisao_Heart_Failure_mlflow.ipynb`

Lista de siglas e abreviaturas

Sigla	Significado
BP	Pressão arterial (*Blood Pressure*)
CV	Validação cruzada (*Cross-Validation*)
DAC	Doença arterial coronariana
ECG	Eletrocardiograma
F1	Média harmônica entre precisão e revocação
FC	Frequência cardíaca
FN	Falso negativo
FP	Falso positivo
HR	Frequência cardíaca (*Heart Rate*)
IC 95%	Intervalo de confiança de 95%
LVH	Hipertrofia ventricular esquerda (*Left Ventricular Hypertrophy*)
M/F	Masculino/feminino
MLflow	Plataforma de rastreamento de experimentos de aprendizado de máquina
PCA	Análise de Componentes Principais (*Principal Component Analysis*)
PPGCC/UFPI	Programa de Pós-Graduação em Ciência da Computação da Universidade Federal do Piauí
Prec. / Rec.	Precisão / revocação (*recall*)
SHAP	*SHapley Additive exPlanations*
SMOTE	*Synthetic Minority Over-sampling Technique* (sobreamostragem sintética)

Sigla	Significado
SQLite	Banco de dados relacional leve
ST	Segmento ST do eletrocardiograma
TA/ATA/NAP/ASY	Angina típica / angina atípica / dor não anginosa / assintomático
TN / TP	Verdadeiro negativo / verdadeiro positivo
UCI	*University of California, Irvine* (repositório de conjuntos de dados)
Y/N	Sim/não

---

1. Introdução e problema

As doenças cardiovasculares estão entre as principais causas de morte no mundo. Um modelo de triagem que identifique pacientes com maior probabilidade de doença cardíaca pode apoiar a priorização de exames e reduzir o tempo até o tratamento. Neste trabalho, o problema é uma **classificação binária**:

- **Classe 1:** paciente com doença cardíaca (`HeartDisease = 1`);
- **Classe 0:** paciente sem doença (`HeartDisease = 0`).

O erro de maior gravidade clínica é o **falso negativo da classe 1**: classificar um paciente doente como "não doente". Nesse caso, o paciente deixa de ser tratado e pode evoluir para óbito. Por isso, além da acurácia, este trabalho dá atenção especial ao **recall e ao F1 da classe 1** (e ao F1 macro, que equilibra as duas classes).

Objetivo: avaliar uma **Árvore de Decisão**, combinando tratamento dos dados, ajuste de hiperparâmetros e engenharia de atributos, e registrar todos os experimentos no **MLflow** para comparar ganhos e perdas de forma reprodutível.

---

2. Base de dados

2.1 Origem e descrição

A base é a **Heart Failure Prediction** (Kaggle, fedesoriano), derivada do **UCI Heart Disease** (Detrano et al., 1989), combinando cinco bases clínicas (Cleveland, Hungria, Suíça, Long Beach VA e Statlog). O arquivo `bases/heart.csv` contém **918 registros** e **12 colunas** (11 atributos + alvo).

2.2 Dicionário de atributos

Atributo	Tipo	Descrição
`Age`	Numérico	Idade (anos)
`Sex`	Categórico	Sexo (M/F)
`ChestPainType`	Categórico	Tipo de dor no peito (TA, ATA, NAP, ASY)
`RestingBP`	Numérico	Pressão arterial em repouso (mm Hg)
`Cholesterol`	Numérico	Colesterol sérico (mm/dl)
`FastingBS`	Binário	Glicemia em jejum > 120 mg/dl (1/0)
`RestingECG`	Categórico	ECG em repouso (Normal, ST, LVH)
`MaxHR`	Numérico	Frequência cardíaca máxima atingida
`ExerciseAngina`	Categórico	Angina induzida por exercício (Y/N)
`Oldpeak`	Numérico	Depressão do segmento ST induzida por exercício
`ST_Slope`	Categórico	Inclinação do segmento ST no pico (Up/Flat/Down)
`HeartDisease`	Binário	Alvo: 1 = doença, 0 = normal

Legenda das siglas dos atributos: `TA` = angina típica; `ATA` = angina atípica; `NAP` = dor não anginosa; `ASY` = assintomático; `M/F` = masculino/feminino; `Y/N` = sim/não; `ST` = segmento ST do eletrocardiograma; `LVH` = hipertrofia ventricular esquerda (*Left Ventricular Hypertrophy*).

2.3 Distribuição e qualidade

Classe	Registros	Proporção
1 (com doença)	508	55,34%
0 (sem doença)	410	44,66%
Total	**918**	**100%**

- **Desbalanceamento leve:** a classe 1 é majoritária (55,34%).
- **Valores ausentes:** não há `NaN` original; porém `Cholesterol` tem **172 zeros** e `RestingBP` tem **1 zero**, fisiologicamente implausíveis. Esses zeros foram convertidos em `NaN` e imputados **dentro do pipeline** (sem vazamento).
- **Duplicatas:** 0.
- **Split:** 80/20 estratificado → 734 treino e 184 teste (102 da classe 1 e 82 da classe 0 no teste).

2.4 Estatísticas descritivas

Variável	Média	Desvio	Mín.	Mediana	Máx.
Age	53,51	9,43	28	54	77
RestingBP	132,40	18,51	0	130	200
Cholesterol	198,80	109,38	0	223	603
FastingBS	0,23	0,42	0	0	1
MaxHR	136,81	25,46	60	138	202
Oldpeak	0,89	1,07	–2,6	0,6	6,2

---

3. Metodologia

3.1 Fluxo de processamento (pipeline)

O modelo é uma **Árvore de Decisão** (`DecisionTreeClassifier`) dentro de um fluxo de processamento (`Pipeline`):

1. **Pré-processamento numérico:** `SimpleImputer` (estratégia testada: mediana, média, moda) + `StandardScaler` ;
2. **Pré-processamento categórico:** `OneHotEncoder` ou `OrdinalEncoder` (comparados);
3. **Modelo:** `DecisionTreeClassifier` .

Tudo é ajustado **somente no treino de cada partição (fold)** da validação cruzada (CV), evitando vazamento.

3.2 Validação e seleção

- Divisão (split) estratificada 80/20 (semente 42); o conjunto de teste é reservado até o fim.
- `RepeatedStratifiedKFold(5 folds × 2 repetições)` para a busca.
- Busca em grade (`GridSearchCV`) com métrica de reajuste (refit) **F1 da classe 1**; acurácia, precisão e recall também são medidos.
- Grade de hiperparâmetros: imputação (3) × `criterion` (2) × `max_depth` (4) × `min_samples_split` (3) × `min_samples_leaf` (3) × `max_features` (2) × `class_weight` (2) = **864 combinações** por codificação; 8.640 ajustes (*fits*) por codificação; **17.280 ajustes** no total (one-hot + ordinal).

Valores testados em cada hiperparâmetro:

Parâmetro	Valores testados
`prep__num__imp__strategy`	`median` , `mean` , `most_frequent`
`modelo__criterion`	`gini` , `entropy`
`modelo__max_depth`	`3` , `5` , `7` , `None`
`modelo__min_samples_split`	`2` , `5` , `10`
`modelo__min_samples_leaf`	`1` , `3` , `5`
`modelo__max_features`	`None` , `sqrt`
`modelo__class_weight`	`None` , `balanced`

- Avaliação no conjunto de teste: acurácia, precisão, recall e F1 para **as duas classes**, F1 macro, IC 95% do F1 da classe 1 (bootstrap com 1.000 reamostragens) e matriz de confusão.

3.3 Fases do notebook

Fase	O que faz
1. Configuração	Semente, MLflow (SQLite), pasta `resultados/execucao_<timestamp>/`
2. Carga/limpeza	Lê `bases/heart.csv` ; zeros de `Cholesterol` / `RestingBP` → `NaN`
3. Preparação	`ColumnTransformer` (imputação + encoding + scaler), split 80/20, CV 5×2
4. Grid search	864 combinações por codificação; one-hot e ordinal; log no MLflow
5. Avaliação	Métricas das duas classes, IC 95%, matriz de confusão, importâncias
6. Baseline	`DummyClassifier(most_frequent)` como referência
7. Interpretação	Importâncias, plot da árvore, verificação de invariância à escala
8. Ablação	Remove 1 atributo por vez; mesmos hiperparâmetros; ambas as classes
9. Engenharia	5 razões/interações clínicas; comparação sem/com
10. Exportação	CSVs, JSON, PNGs e ZIP na pasta da execução; artefatos no MLflow
11. MLflow	Runs pai/filhas, parâmetros, métricas, modelos e artefatos

3.4 Engenharia de atributos testada

Atributo derivado	Fórmula	Motivação
`FC_pct_teorica`	`MaxHR / (220 – Age)`	% da FC máxima teórica
`Chol_por_Idade`	`Cholesterol / Age`	colesterol relativo à idade
`BP_por_Idade`	`RestingBP / Age`	pressão relativa à idade
`Oldpeak_por_FC`	`Oldpeak / MaxHR`	depressão ST por batimento
`Angina_x_Oldpeak`	`(ExerciseAngina == 'Y') × Oldpeak`	interação angina × ST

As razões são calculadas **linha a linha**, antes da divisão (split), sem vazamento.

---

4. Resultados

4.1 Busca em grade (grid search) e hiperparâmetros selecionados

Codificação	Imputação	class_weight	criterion	max_depth	max_features	min_samples_leaf	min_samples_split
one-hot	mediana	balanced	entropy	3	None	1	2
ordinal	moda	None	gini	3	sqrt	1	2

A árvore escolhida ficou **rasa (profundidade 3)** nas duas codificações. A busca avaliou 864 combinações por codificação (17.280 ajustes no total), com F1 da classe 1 como critério.

4.2 Comparação entre codificações one-hot e ordinal no conjunto de teste

Codificação	Acurácia	Prec_c0	Rec_c0	F1_c0	Prec_c1	Rec_c1	F1_c1	F1_macro	IC95 F1_c1
ordinal	0,8098	0,8406	0,7073	0,7682	0,7913	**0,8922**	**0,8387**	0,8035	0,7817–0,8879
one-hot	**0,8207**	0,7692	**0,8537**	0,8092	**0,8710**	0,7941	0,8308	**0,8200**	0,7650–0,8865

Interpretação: a codificação **ordinal** tem maior **F1_c1** e **recall_c1** (melhor para não deixar doentes sem diagnóstico), enquanto a **one-hot** tem maior acurácia, precisão_c1 e F1_macro. Os intervalos de confiança do F1_c1 se sobrepõem, então a diferença não é conclusiva.

4.3 Referência (baseline) da classe majoritária

O classificador ingênuo (`DummyClassifier` , estratégia `most_frequent`) prediz sempre a classe 1:

Métrica	Valor
Acurácia	0,5543
Precisão_c1	0,5543
Recall_c1	1,0000
F1_c1	0,7133
F1_c0	0,0000

Métrica	Valor
F1_macro	0,3566

Ou seja, classificar sempre a classe majoritária já resulta em F1_c1 = 0,71; o modelo precisa superar essa referência — e supera (0,8387 no ordinal). A referência tem **0 falsos negativos da classe 1** (revocação da classe 1 = 1), mas **82 falsos positivos** (toda a classe 0 incorreta), o que evidencia por que a acurácia isolada pode ser enganosa.

4.4 Ablação de atributos (seleção de variáveis)

Cada atributo foi removido individualmente, mantendo os melhores hiperparâmetros e `class_weight=None`.

Cenário	Atributo removido	Acurácia	F1_c0	F1_c1	F1_macro
todos	nenhum	0,8098	0,7682	**0,8387**	0,8035
sem_RestingBP	RestingBP	0,8207	**0,8136**	0,8272	**0,8204**
sem_Cholesterol	Cholesterol	0,8207	**0,8136**	0,8272	**0,8204**
sem_FastingBS	FastingBS	0,8207	**0,8136**	0,8272	**0,8204**
sem_Age	Age	0,8152	0,8068	0,8229	0,8149
sem_ExerciseAngina	ExerciseAngina	0,7989	0,7933	0,8042	0,7988
sem_ST_Slope	ST_Slope	0,7772	0,7630	0,7897	0,7764
sem_MaxHR	MaxHR	0,7500	0,6933	0,7890	0,7412
sem_Sex	Sex	0,7391	0,7073	0,7647	0,7360
sem_ChestPainType	ChestPainType	0,7391	0,7073	0,7647	0,7360
sem_RestingECG	RestingECG	0,7391	0,7073	0,7647	0,7360
sem_Oldpeak	Oldpeak	0,7391	0,7073	0,7647	0,7360

Interpretação: - **Nenhuma remoção melhorou o F1_c1**: o conjunto completo é o melhor (0,8387). - Remover `RestingBP`, `Cholesterol` ou `FastingBS` **melhora a acurácia (0,8207), o F1_c0 (0,8136) e o F1_macro (0,8204)**, mas **piora o recall/F1 da classe 1** — compromisso entre as classes. - Remover `ST_Slope` ou `MaxHR` **piora** o F1_c1, indicando que são informativos. - Remover `Sex`, `ChestPainType`, `RestingECG` ou `Oldpeak` leva o F1_c1 a 0,7647 (a árvore passa a usar outro caminho de decisão). - Conclusão: para **maximizar F1_c1**, manter todos os atributos; para **equilibrar as classes (F1_macro)**, remover `RestingBP` / `Cholesterol` / `FastingBS` é uma alternativa.

4.5 Engenharia de atributos (razões e interações clínicas)

Cenário	Nº atributos	Acurácia	F1_c0	F1_c1	F1_macro	F1_CV
sem_engenharia	11	0,8098	0,7682	0,8387	0,8035	**0,8604**
com_engenharia	16	**0,8261**	**0,7838**	**0,8545**	**0,8192**	0,7946

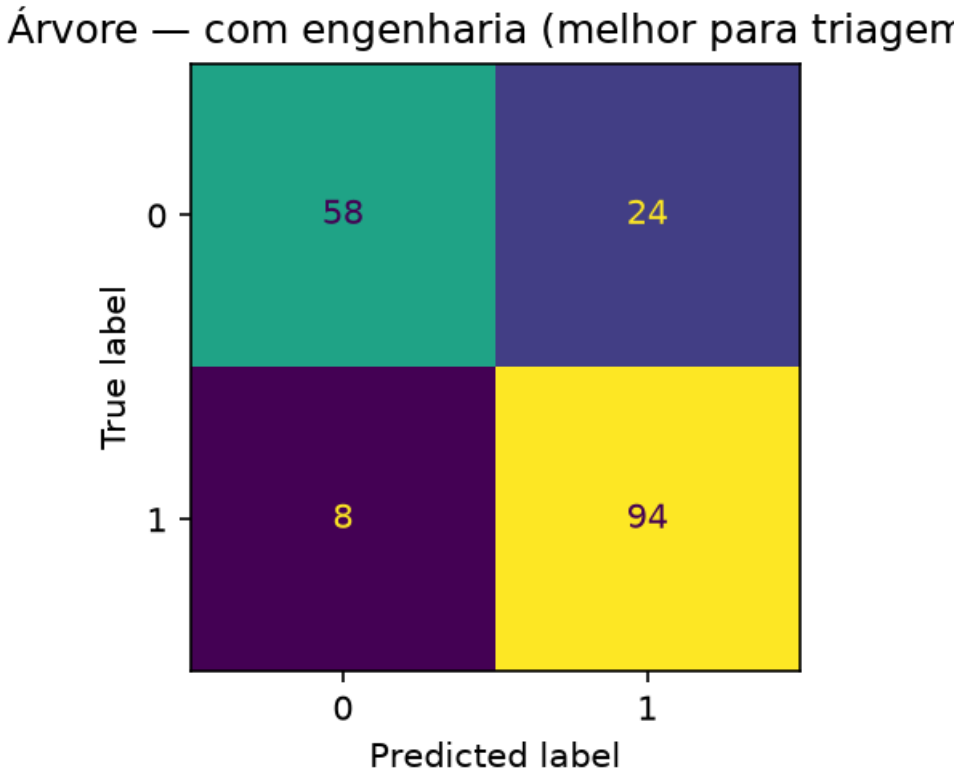
Melhora no conjunto de teste: F1_c1 +0,0158 (0,8387 → 0,8545), recall_c1 +0,0294 (0,8922 → 0,9216), acurácia +0,0163, F1_macro +0,0157.

Limitação importante: o **F1 da validação cruzada (CV) apresentou redução** (0,8604 → 0,7946). Ou seja, a melhora no conjunto de teste **não é confirmada pela CV** e pode ser efeito da divisão específica (184 amostras). A engenharia deve ser tratada como **com potencial, porém não conclusiva**, até validação externa.

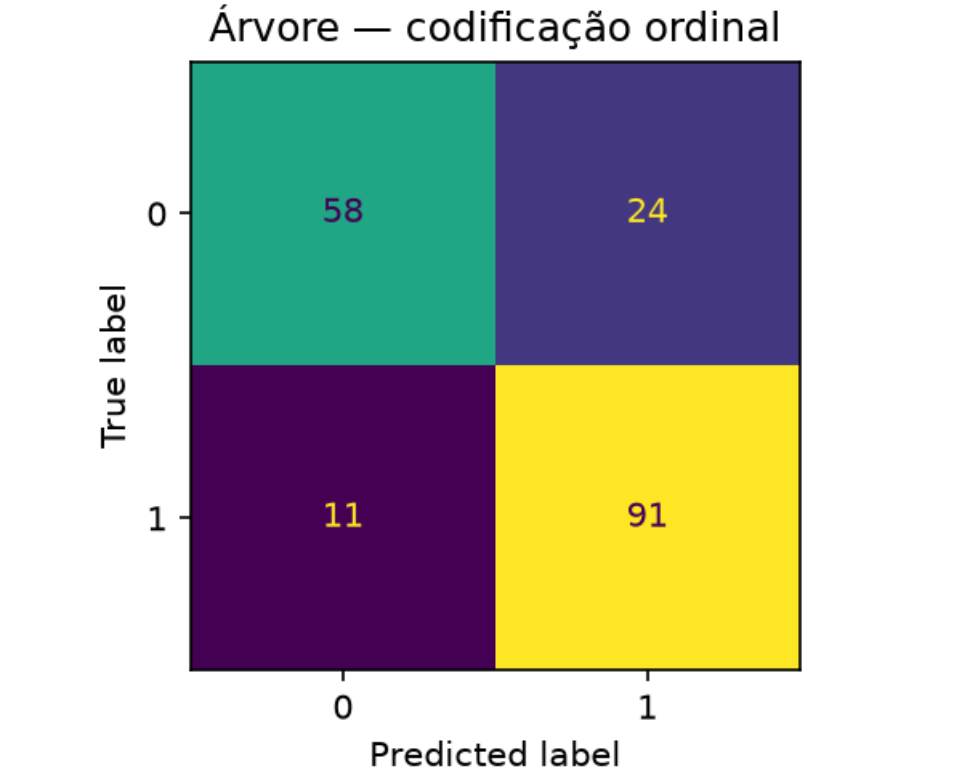
4.6 Matrizes de confusão e o erro de maior gravidade clínica

Com o teste de 184 pacientes (82 da classe 0 e 102 da classe 1):

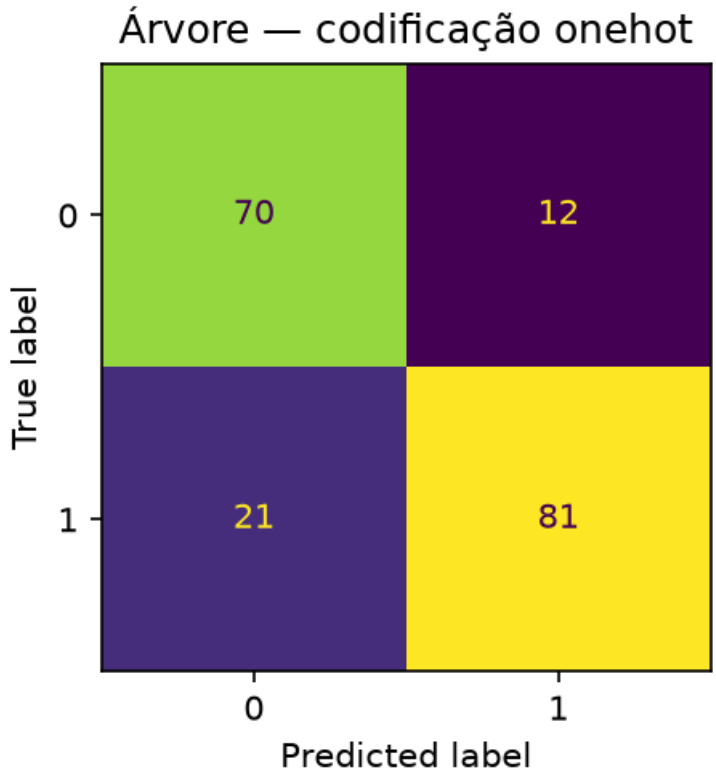
Modelo	TN	FP	FN (classe 1)	TP	Recall_c1	F1_c1	F1_CV
com_engenharia	58	24	**8**	94	**0,9216**	**0,8545**	0,7946
ordinal	58	24	11	91	0,8922	0,8387	**0,8604**
one-hot	70	12	21	81	0,7941	0,8308	0,8550
baseline	0	82	0	102	1,0000	0,7133	—



Matriz de confusão — com engenharia (melhor no teste para triagem)



Matriz de confusão — ordinal



Matriz de confusão — one-hot

O erro de maior gravidade clínica: o **falso negativo da classe 1** (paciente doente previsto como "não doente"). No conjunto de teste, o `com_engenharia` é o melhor para triagem: **8 falsos negativos** contra 11 do ordinal e 21 do one-hot, com o **mesmo número de falsos positivos (24)** e o maior **F1_c1 (0,8545)**. **Limitação:** o **F1 da CV apresentou redução** (0,7946 vs 0,8604 do ordinal), então a melhora no teste **não é confirmada pela CV** e pode refletir a variância do conjunto de teste reservado. Os dois melhores para triagem são `com_engenharia` **e ordinal** (8 e 11 falsos negativos); a escolha é um compromisso entre desempenho no teste e robustez na CV, e exige validação externa.

4.7 Síntese das transformações e impacto nas métricas

Em consonância com a solicitação da atividade, a tabela abaixo resume as principais transformações de preparação dos dados e o efeito nas métricas (melhoria ou piora):

Transformação	Antes	Depois	Efeito
Codificação one-hot → ordinal	F1_c1 0,8308	**0,8387**	ganho no F1_c1/recall
Imputação (mediana × moda)	—	—	escolhida pela grade
`class_weight=balanced`	≈ igual	≈ igual	**sem efeito** (desbalanceamento leve)
Escalonamento (`StandardScaler`)	idêntico	idêntico	**invariante** (árvore)
Remover `RestingBP` / `Cholesterol` / `FastingBS`	F1_c1 0,8387	0,8272	**piora F1_c1**, melhora F1_macro
Remover `ST_Slope` / `MaxHR`	F1_c1 0,8387	0,7897 / 0,7890	**piora**
Engenharia de atributos	F1_c1 0,8387	**0,8545** (teste)	melhora no teste, **redução na CV**
Variação de hiperparâmetros one-hot (`max_depth=4` , `min_samples_leaf=10`)	F1 0,8308	0,8119	**piora**

---

5. MLflow: registro e tabulação dos experimentos

Todos os experimentos foram registrados no MLflow, no experimento `heart_failure_arvore_decisao` , com rastreamento (tracking) local em SQLite (`mlflow.db`) e artefatos em `mlruns/` .

- **111 execuções (runs)** registradas (execuções pai e filhas).
- Cada execução (run) guarda: **parâmetros** (codificação, imputação, hiperparâmetros, atributo removido,

engenharia, `class_weight`), **métricas** (F1, acurácia, precisão, recall, F1 macro, IC 95%), **modelo** (`mlflow.sklearn.log_model`) e **artefatos** (CSVs, JSON, PNGs, ZIP).
- A tabela completa está em **`docs/mlflow_runs.csv`** (exportada via `mlflow.search_runs`), com as colunas de execução (run), status, data, parâmetros e métricas.

Execuções principais: `arvore_onehot`, `arvore_ordinal`, `baseline_classe_majoritaria`, `ablacao_atributos` (com 12 execuções filhas), `engenharia_features` (com `sem_engenharia` e `com_engenharia`) e `relatorio_artefatos`.

---

6. Avaliação comparativa entre execuções

Execução	O que mudou	Melhor F1_c1	F1_macro	Efeito
`20261022_081800`	Versão inicial: one-hot × ordinal + baseline	0,8387	—	referência (só classe 1)
`20261022_083734`	+ ablação com `class_weight` None/balanced	0,8387	0,8035	`balanced` ≈ `None`
`20261022_090449`	Ablação simplificada (sem `balanced`)	0,8387	—	foco didático
`20261022_093147`	+ engenharia de atributos	**0,8545** (com)	**0,8192** (com)	melhora no teste, **redução na CV**
`20261022_094826`	Variação de hiperparâmetros one-hot (`max_depth=4`, `min_samples_leaf=10`)	0,8119 (one-hot)	—	**piorou** o teste
`20261026_075517`	Métricas para as duas classes (versão final)	0,8387 (ordinal) / 0,8545 (com eng.)	0,8035 / 0,8192	versão consolidada

Considerações sobre a evolução: 1. Os **hiperparâmetros** escolhidos pela grade ficaram estáveis (profundidade 3), exceto a variação de `094826`, que **piorou** o teste. 2. A **engenharia de atributos** foi a única mudança que **apresentou melhora no conjunto de teste** (F1_c1 0,8387 → 0,8545), mas **apresentou redução na CV** (0,8604 → 0,7946) — ganho **não robusto**. 3. A **ablação** mostrou que remover atributos **não melhora o F1_c1**; só melhora o F1_macro ao custo da revocação (recall) da classe 1. 4. `class_weight='balanced'` **não teve efeito** relevante, coerente com o desbalanceamento leve (55/45). 5. A mudança para **reportar as duas classes** alterou a interpretação: o que parecia “melhor” pela classe 1 nem sempre é melhor no F1_macro.

---

7. Discussão e trabalhos relacionados

Trabalho	Contribuição	Relação com este trabalho
Qadri et al. (2023), IEEE Access	Técnica de engenharia de atributos (*feature engineering*) para predição de doença cardíaca	Justifica a criação de atributos derivados
Abass & Bathla (2025), Springer	Aprendizado de máquina + engenharia de atributos	Reforça a engenharia como etapa
Gárate-Escamilla et al. (2020), Informatics in Medicine Unlocked	Seleção de atributos + PCA	Compara seleção/transformação
Hasnat et al. (2025), arXiv	Engenharia de atributos + SHAP + árvores substitutas	Interpretabilidade
Page et al. (1970), Circulation	Idade, colesterol e triglicerídeos na predição de DAC	Base para `Chol_por_Idade`
Folsom et al. (2003), Diabetes Care	Fatores de risco para DAC	Contexto clínico
Detrano et al. (1989) / Janosi et al. (1988)	Base UCI Heart Disease	Origem dos dados
Fox et al. (1971)	Fórmula `FCmax ≈ 220 – idade`	Base de `FC_pct_teorica`

Justificativa das razões: as variáveis originais (`MaxHR`, `Oldpeak`, `Cholesterol`, `RestingBP`, `ExerciseAngina`) são indicadores clínicos conhecidos. As razões buscam normalizar por idade/FC e capturar interações (angina × depressão ST), o que ajuda a árvore a representar relações “diagonais” com menos cortes. A literatura apoia a engenharia de atributos em doença cardíaca, mas **as razões específicas aqui testadas são hipóteses exploratórias** e precisam de validação externa.

Limitações: - Base pequena (918) e teste de apenas 184 pacientes → intervalos de confiança largos. - Uma única árvore (sem ensemble) e sem validação externa. - A engenharia apresentou melhora no conjunto de teste, mas redução na CV → ganho não conclusivo. - Não foram testados ajuste de limiar, SMOTE (*Synthetic Minority Over-sampling Technique*) ou outros modelos.

8. Conclusão e recomendações

- **Melhor modelo para triagem no conjunto de teste:** `com_engenharia` (codificação ordinal + 5 atributos derivados), com **8 falsos negativos**, revocação da classe 1 (*recall_c1*) = 0,9216 e F1_c1 = 0,8545 — mesmo número de falsos positivos (24) do ordinal.
- **Modelo mais robusto na CV:** ordinal sem engenharia, com F1_CV = 0,8604 (o `com_engenharia` tem F1_CV = 0,7946).
- **Engenharia de atributos:** apresentou melhora no conjunto de teste, mas **não confirmou o ganho na CV** → tratar como com potencial e não conclusiva.
- **Ablação:** manter todos os atributos maximiza o F1_c1; remover `RestingBP` / `Cholesterol` / `FastingBS` melhora o F1_macro, mas aumenta o risco de falso negativo da classe 1.
- **Recomendação clínica:** para triagem, priorizar **recall/F1 da classe 1** (`com_engenharia` no teste, ordinal como alternativa robusta), avaliar **ajuste de limiar** e validar em base externa antes de uso real.
- **MLflow:** as 111 execuções (runs) permitem reproduzir e comparar todos os experimentos.

9. Referências

1. FEDESORIANO. **Heart Failure Prediction Dataset**. Kaggle, 2021. Disponível em: https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction
2. DETRANO, R. et al. International application of a new probability algorithm for the diagnosis of coronary artery disease. **American Journal of Cardiology**, 1989.
3. JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. **Heart Disease**. UCI Machine Learning Repository, 1988.
4. QADRI, A. M. et al. Effective Feature Engineering Technique for Heart Disease Prediction With Machine Learning. **IEEE Access**, 2023.
5. ABASS, A.; BATHLA, G. Heart Disease Prediction Using Machine Learning with Feature Engineering. **Springer**, 2025.
6. GÁRATE-ESCAMILLA, A. K.; HAJJAM EL HASSANI, A.; ANDRÈS, E. Classification models for heart disease prediction using feature selection and PCA. **Informatics in Medicine Unlocked**, 2020.
7. HASNAT, M. A. et al. Interpretable Heart Disease Prediction via a Weighted Ensemble Model. **arXiv:2511.01947**, 2025.
8. PAGE, I. H. et al. Prediction of Coronary Heart Disease Based on Clinical Suspicion, Age, Total Cholesterol, and Triglyceride. **Circulation**, 1970.
9. FOLSOM, A. R. et al. Prediction of Coronary Heart Disease in Middle-Aged Adults With Diabetes. **Diabetes Care**, 2003.
10. FOX, S. M.; NAUGHTON, J. P.; HASKELL, W. L. Physical activity and the prevention of coronary heart disease. **Annals of Clinical Research**, 1971.