UNIVERSIDADE FEDERAL DO PIAUÍ
PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

Disciplina: Aprendizado de Máquina

Predição de Doença Cardíaca com Árvore de Decisão: tratamento de dados, hiperparâmetros e engenharia de atributos

Integrantes:

Arthur Fernando Elvas Bohn (20261001997)

Diego Cordeiro de Oliveira (20261002180)

Keoma de Sousa Coelho (20261004952)

Professor: Dr. Vinicius Ponte Machado

Teresina, 27 de outubro de 2026

LISTA DE ABREVIATURAS E SIGLAS

BP	Pressão arterial (*Blood Pressure*)
CV	Validação cruzada (*Cross-Validation*)
DAC	Doença arterial coronariana
ECG	Eletrocardiograma
F1	Média harmônica entre precisão e revocação
FC	Frequência cardíaca
FN	Falso negativo
FP	Falso positivo
HR	Frequência cardíaca (*Heart Rate*)
IC 95%	Intervalo de confiança de 95%
LVH	Hipertrofia ventricular esquerda (*Left Ventricular Hypertrophy*)
M/F	Masculino/feminino
MLflow	Plataforma de rastreamento de experimentos de aprendizado de máquina
PCA	Análise de Componentes Principais (*Principal Component Analysis*)
PPGCC/UFPI	Programa de Pós-Graduação em Ciência da Computação da Universidade Federal do Piauí
Prec. / Rec.	Precisão / revocação (*recall*)
SHAP	*SHapley Additive exPlanations*
SMOTE	*Synthetic Minority Over-sampling Technique* (sobreamostragem sintética)
SQLite	Banco de dados relacional leve
ST	Segmento ST do eletrocardiograma
TA/ATA/NAP/ASY	Angina típica / angina atípica / dor não anginosa / assintomático
TN / TP	Verdadeiro negativo / verdadeiro positivo
UCI	*University of California, Irvine* (repositório de conjuntos de dados)
Y/N	Sim/não

SUMÁRIO

1 Introdução e problema..... 4
2 Base de dados..... 4
2.1 Origem e descrição..... 4
2.2 Dicionário de atributos..... 4
2.3 Distribuição e qualidade..... 5
2.4 Estatísticas descritivas..... 6
3 Metodologia..... 6
3.1 Fluxo de processamento (pipeline)..... 6
3.2 Validação e seleção..... 6
3.3 Fases do notebook..... 7
3.4 Engenharia de atributos testada..... 8
4 Resultados..... 8
4.1 Busca em grade e hiperparâmetros selecionados..... 8
4.2 Comparação entre as codificações one-hot e ordinal..... 8
4.3 Referência (baseline) da classe majoritária..... 9
4.4 Ablação de atributos..... 9
4.5 Engenharia de atributos (razões e interações clínicas)..... 10
4.6 Matrizes de confusão e o erro de maior gravidade clínica..... 11
4.7 Síntese das transformações e impacto nas métricas..... 13
5 MLflow: registro e tabulação dos experimentos..... 13
6 Avaliação comparativa entre execuções..... 14
7 Discussão e trabalhos relacionados..... 15
8 Conclusão e recomendações..... 16
Referências..... 16

1 Introdução e problema

As doenças cardiovasculares figuram entre as principais causas de morte no mundo. Um modelo de triagem capaz de identificar pacientes com maior probabilidade de doença cardíaca pode apoiar a priorização de exames e reduzir o tempo até o início do tratamento. Neste trabalho, o problema é formulado como uma classificação binária, em que a classe 1 corresponde a pacientes com doença cardíaca (*HeartDisease = 1*) e a classe 0, a pacientes sem a doença (*HeartDisease = 0*).

O erro de maior gravidade clínica é o falso negativo da classe 1, isto é, classificar um paciente doente como "não doente". Nessa situação, o paciente deixa de receber tratamento e pode evoluir para óbito. Por esse motivo, além da acurácia, este trabalho dedica atenção especial à revocação (*recall*) e ao F1 da classe 1, bem como ao F1 macro, que equilibra o desempenho entre as duas classes.

O objetivo deste trabalho é avaliar uma Árvore de Decisão combinando tratamento dos dados, ajuste de hiperparâmetros e engenharia de atributos, com o registro de todos os experimentos na plataforma MLflow, de modo a comparar ganhos e perdas de forma reprodutível.

2 Base de dados

2.1 Origem e descrição

Utilizou-se a base *Heart Failure Prediction*, disponibilizada no Kaggle por fedesoriano (Heart Failure Prediction – Kaggle), derivada da base UCI *Heart Disease* (Detrano et al., 1989) e resultante da combinação de cinco bases clínicas: Cleveland, Hungria, Suíça, Long Beach VA e Statlog. O arquivo *bases/heart.csv* contém 918 registros e 12 colunas, sendo 11 atributos preditores e a variável-alvo.

2.2 Dicionário de atributos

A Tabela 1 descreve os atributos da base, seus tipos e significados.

Tabela 1 – Dicionário de atributos da base de dados

Atributo	Tipo	Descrição
Age	Numérico	Idade (anos)
Sex	Categórico	Sexo (M/F)

Atributo	Tipo	Descrição
ChestPainType	Categórico	Tipo de dor no peito (TA, ATA, NAP, ASY)
RestingBP	Numérico	Pressão arterial em repouso (mm Hg)
Cholesterol	Numérico	Colesterol sérico (mm/dl)
FastingBS	Binário	Glicemia em jejum > 120 mg/dl (1/0)
RestingECG	Categórico	ECG em repouso (Normal, ST, LVH)
MaxHR	Numérico	Frequência cardíaca máxima atingida
ExerciseAngina	Categórico	Angina induzida por exercício (Y/N)
Oldpeak	Numérico	Depressão do segmento ST induzida por exercício
ST_Slope	Categórico	Inclinação do segmento ST no pico (Up/Flat/Down)
HeartDisease	Binário	Alvo: 1 = doença; 0 = normal

Fonte: adaptado de fedesoriano (2021). Legenda: TA = angina típica; ATA = angina atípica; NAP = dor não anginosa; ASY = assintomático; M/F = masculino/feminino; Y/N = sim/não; ST = segmento ST do eletrocardiograma; LVH = hipertrofia ventricular esquerda (*Left Ventricular Hypertrophy*).

2.3 Distribuição e qualidade

A distribuição das classes é apresentada na Tabela 2. Observa-se um desbalanceamento leve, com a classe 1 sendo majoritária (55,34%).

Tabela 2 – Distribuição das classes da variável-alvo

Classe	Registros	Proporção
1 (com doença)	508	55,34%
0 (sem doença)	410	44,66%
Total	**918**	**100%**

Fonte: elaborado pelos autores (2026).

Quanto à qualidade dos dados, não há valores ausentes (*NaN*) na base original. Entretanto, o atributo *Cholesterol* apresenta 172 registros com valor zero e *RestingBP*, um registro, valores fisiologicamente implausíveis. Esses zeros foram convertidos em *NaN* e imputados dentro do *pipeline*, evitando vazamento de informação. Como *Chol_por_Idade* depende de *Cholesterol*, esses registros também são imputados no atributo derivado. Ressalta-se ainda que a base não contém triglicerídeos, variável utilizada em alguns estudos clínicos (por exemplo, Page et al., 1970). Não foram encontrados registros duplicados.

Os dados foram divididos de forma estratificada na proporção 80/20, resultando em 734 registros de treino e 184 de teste, dos quais 102 pertencem à classe 1 e 82 à classe 0.

2.4 Estatísticas descritivas

A Tabela 3 resume as estatísticas descritivas das variáveis numéricas.

Tabela 3 – Estatísticas descritivas das variáveis numéricas

Variável	Média	Desvio	Mín.	Mediana	Máx.
Age	53,51	9,43	28	54	77
RestingBP	132,40	18,51	0	130	200
Cholesterol	198,80	109,38	0	223	603
FastingBS	0,23	0,42	0	0	1
MaxHR	136,81	25,46	60	138	202
Oldpeak	0,89	1,07	−2,6	0,6	6,2

Fonte: elaborado pelos autores (2026).

3 Metodologia

3.1 Fluxo de processamento (pipeline)

O modelo avaliado é uma Árvore de Decisão (*DecisionTreeClassifier*), implementada no notebook *Arvore_Decisao_Heart_Failure_mlflow.ipynb* e encapsulada em um fluxo de processamento (*Pipeline*) composto por três etapas: (i) pré-processamento numérico, com *SimpleImputer* — tendo sido testadas as estratégias mediana, média e moda — seguido de *StandardScaler*; (ii) pré-processamento categórico, com comparação entre *OneHotEncoder* e *OrdinalEncoder*; e (iii) o classificador *DecisionTreeClassifier*.

Todas as etapas são ajustadas exclusivamente sobre a partição de treino de cada *fold* da validação cruzada (CV), o que evita vazamento de informação.

3.2 Validação e seleção

O conjunto de dados foi dividido de forma estratificada na proporção 80/20 (semente 42), e o conjunto de teste foi reservado até a etapa final. Na busca de hiperparâmetros, empregou-se *RepeatedStratifiedKFold* com cinco *folds* e duas repetições. A busca em grade (*GridSearchCV*) utilizou como métrica de reajuste (*refit*) o F1 da classe 1, sendo também medidas a acurácia, a precisão e a revocação.

A grade de hiperparâmetros combinou imputação (3) × *criterion* (2) × *max_depth* (4) × *min_samples_split* (3) × *min_samples_leaf* (3) × *max_features* (2) × *class_weight* (2), totalizando 864 combinações por codificação. Isso corresponde a 8.640 ajustes (*fits*) por codificação e a

17.280 ajustes no total, considerando as codificações one-hot e ordinal. Os valores testados para cada hiperparâmetro constam na Tabela 4.

Tabela 4 – Valores testados para cada hiperparâmetro

Parâmetro	Valores testados
prep__num__imp__strategy	*median*, *mean*, *most_frequent*
modelo__criterion	*gini*, *entropy*
modelo__max_depth	*3*, *5*, *7*, *None*
modelo__min_samples_split	*2*, *5*, *10*
modelo__min_samples_leaf	*1*, *3*, *5*
modelo__max_features	*None*, *sqrt*
modelo__class_weight	*None*, *balanced*

Fonte: elaborado pelos autores (2026).

A avaliação no conjunto de teste considerou acurácia, precisão, revocação e F1 para ambas as classes, além do F1 macro, do intervalo de confiança de 95% (IC 95%) do F1 da classe 1 — estimado por *bootstrap* com 1.000 reamostragens — e da matriz de confusão.

3.3 Fases do notebook

O experimento foi organizado em onze fases, sintetizadas na Tabela 5.

Tabela 5 – Fases do notebook e respectivas atividades

Fase	Atividades
1. Configuração	Semente, MLflow (SQLite) e pasta *resultados/execucao_<timestamp>/*
2. Carga e limpeza	Leitura de *bases/heart.csv*; zeros de *Cholesterol*/*RestingBP* convertidos em *NaN*
3. Preparação	*ColumnTransformer* (imputação + codificação + escalonamento), divisão 80/20 e CV 5×2
4. Busca em grade	864 combinações por codificação; one-hot e ordinal; registro no MLflow
5. Avaliação	Métricas das duas classes, IC 95%, matriz de confusão e importâncias
6. Referência (baseline)	*DummyClassifier(most_frequent)* como referência
7. Interpretação	Importâncias, visualização da árvore e verificação de invariância à escala
8. Ablação	Remoção de um atributo por vez, com os mesmos hiperparâmetros; ambas as classes
9. Engenharia	Cinco razões/interações clínicas; comparação sem e com engenharia
10. Exportação	CSVs, JSON, PNGs e ZIP na pasta da execução; artefatos no MLflow
11. MLflow	Execuções pai/filhas, parâmetros, métricas, modelos e artefatos

Fonte: elaborado pelos autores (2026).

3.4 Engenharia de atributos testada

Foram propostos cinco atributos derivados, apresentados na Tabela 6. As razões são calculadas linha a linha, antes da divisão dos dados, sem risco de vazamento.

Tabela 6 – Atributos derivados pela engenharia de atributos

Atributo derivado	Fórmula	Motivação
FC_pct_teorica	*MaxHR / (220 − Age)*	% da FC máxima teórica
Chol_por_Idade	*Cholesterol / Age*	Colesterol relativo à idade
BP_por_Idade	*RestingBP / Age*	Pressão relativa à idade
Oldpeak_por_FC	*Oldpeak / MaxHR*	Depressão ST por batimento
Angina_x_Oldpeak	*(ExerciseAngina == 'Y') × Oldpeak*	Interação angina × ST

Fonte: elaborado pelos autores (2026).

4 Resultados

4.1 Busca em grade e hiperparâmetros selecionados

A Tabela 7 apresenta os hiperparâmetros selecionados pela busca em grade (*grid search*) para cada codificação.

Tabela 7 – Hiperparâmetros selecionados pela busca em grade

Codificação	Imputação	class_weight	criterion	max_depth	max_features	min_samples_leaf	min_samples_split
one-hot	mediana	balanced	entropy	3	None	1	2
ordinal	moda	None	gini	3	sqrt	1	2

Fonte: elaborado pelos autores (2026).

Em ambas as codificações, a árvore selecionada é rasa, com profundidade 3. A busca avaliou 864 combinações por codificação (17.280 ajustes no total), tendo o F1 da classe 1 como critério de seleção.

4.2 Comparação entre as codificações one-hot e ordinal

A Tabela 8 compara o desempenho das duas codificações no conjunto de teste.

Tabela 8 – Desempenho das codificações one-hot e ordinal no conjunto de teste

Codificação	Acurácia	Prec_c0	Rec_c0	F1_c0	Prec_c1	Rec_c1	F1_c1	F1_macro	IC95 F1_c1
ordinal	0,8098	0,8406	0,7073	0,7682	0,7913	**0,8922**	**0,8387**	0,8035	0,7817–0,8879
one-hot	**0,8207**	0,7692	**0,8537**	0,8092	**0,8710**	0,7941	0,8308	**0,8200**	0,7650–0,8865

Fonte: elaborado pelos autores (2026). Nota: valores em negrito indicam o melhor resultado de cada métrica.

A codificação ordinal obteve maiores F1_c1 e revocação da classe 1 (*recall_c1*), o que a torna preferível para evitar que pacientes doentes fiquem sem diagnóstico. Por sua vez, a codificação one-hot apresentou maiores acurácia, precisão da classe 1 e F1_macro. Como os intervalos de confiança do F1_c1 se sobrepõem, a diferença entre as codificações não é conclusiva.

4.3 Referência (baseline) da classe majoritária

O classificador ingênuo (*DummyClassifier*, com estratégia *most_frequent*) prediz sempre a classe 1. Seus resultados constam na Tabela 9.

Tabela 9 – Desempenho do classificador de referência (classe majoritária)

Métrica	Valor
Acurácia	0,5543
Precisão_c1	0,5543
Recall_c1	1,0000
F1_c1	0,7133
F1_c0	0,0000
F1_macro	0,3566

Fonte: elaborado pelos autores (2026).

Ou seja, classificar todos os pacientes na classe majoritária já resulta em F1_c1 = 0,71; portanto, o modelo precisa superar essa referência, o que de fato ocorre (0,8387 com a codificação ordinal). A referência não produz falsos negativos da classe 1 (revocação da classe 1 igual a 1), mas gera 82 falsos positivos, uma vez que erra toda a classe 0. Esse resultado evidencia por que a acurácia, analisada isoladamente, pode ser enganosa.

4.4 Ablação de atributos

Na análise de ablação (seleção de variáveis), cada atributo foi removido individualmente, mantendo-se os melhores hiperparâmetros e *class_weight=None*. Os resultados são apresentados na Tabela 10.

Tabela 10 – Resultados da ablação de atributos

Cenário	Atributo removido	Acurácia	F1_c0	F1_c1	F1_macro
todos	nenhum	0,8098	0,7682	**0,8387**	0,8035
sem_RestingBP	*RestingBP*	0,8207	**0,8136**	0,8272	**0,8204**
sem_Cholesterol	*Cholesterol*	0,8207	**0,8136**	0,8272	**0,8204**

Cenário	Atributo removido	Acurácia	F1_c0	F1_c1	F1_macro
sem_FastingBS	*FastingBS*	0,8207	**0,8136**	0,8272	**0,8204**
sem_Age	*Age*	0,8152	0,8068	0,8229	0,8149
sem_ExerciseAngina	*ExerciseAngina*	0,7989	0,7933	0,8042	0,7988
sem_ST_Slope	*ST_Slope*	0,7772	0,7630	0,7897	0,7764
sem_MaxHR	*MaxHR*	0,7500	0,6933	0,7890	0,7412
sem_Sex	*Sex*	0,7391	0,7073	0,7647	0,7360
sem_ChestPainType	*ChestPainType*	0,7391	0,7073	0,7647	0,7360
sem_RestingECG	*RestingECG*	0,7391	0,7073	0,7647	0,7360
sem_Oldpeak	*Oldpeak*	0,7391	0,7073	0,7647	0,7360

Fonte: elaborado pelos autores (2026).

Nenhuma remoção melhorou o F1_c1, de modo que o conjunto completo de atributos apresenta o melhor resultado (0,8387). A remoção de *RestingBP*, *Cholesterol* ou *FastingBS* melhora a acurácia (0,8207), o F1_c0 (0,8136) e o F1_macro (0,8204), mas reduz a revocação e o F1 da classe 1, o que caracteriza um compromisso entre as classes. Já a remoção de *ST_Slope* ou de *MaxHR* piora o F1_c1, indicando que esses atributos são informativos. A exclusão de *Sex*, *ChestPainType*, *RestingECG* ou *Oldpeak* reduz o F1_c1 para 0,7647, pois a árvore passa a adotar outro caminho de decisão.

Conclui-se que, para maximizar o F1_c1, todos os atributos devem ser mantidos; por outro lado, para equilibrar o desempenho entre as classes (F1_macro), a remoção de *RestingBP*, *Cholesterol* ou *FastingBS* constitui uma alternativa.

4.5 Engenharia de atributos (razões e interações clínicas)

A Tabela 11 compara o desempenho do modelo sem e com os atributos derivados.

Tabela 11 – Comparação do modelo sem e com engenharia de atributos

Cenário	Nº de atributos	Acurácia	F1_c0	F1_c1	F1_macro	F1_CV
sem_engenharia	11	0,8098	0,7682	0,8387	0,8035	**0,8604**
com_engenharia	16	**0,8261**	**0,7838**	**0,8545**	**0,8192**	0,7946

Fonte: elaborado pelos autores (2026).

No conjunto de teste, observou-se melhora de +0,0158 no F1_c1 (de 0,8387 para 0,8545), de +0,0294 na revocação da classe 1 (de 0,8922 para 0,9216), de +0,0163 na acurácia e de +0,0157 no F1_macro.

Há, contudo, uma limitação importante: o F1 obtido na validação cruzada apresentou redução (de 0,8604 para 0,7946). Assim, a melhora observada no conjunto de teste não é confirmada pela CV e pode decorrer da divisão específica dos dados (184 amostras). A engenharia de atributos deve, portanto, ser considerada promissora, porém não conclusiva, até que haja validação externa.

4.6 Matrizes de confusão e o erro de maior gravidade clínica

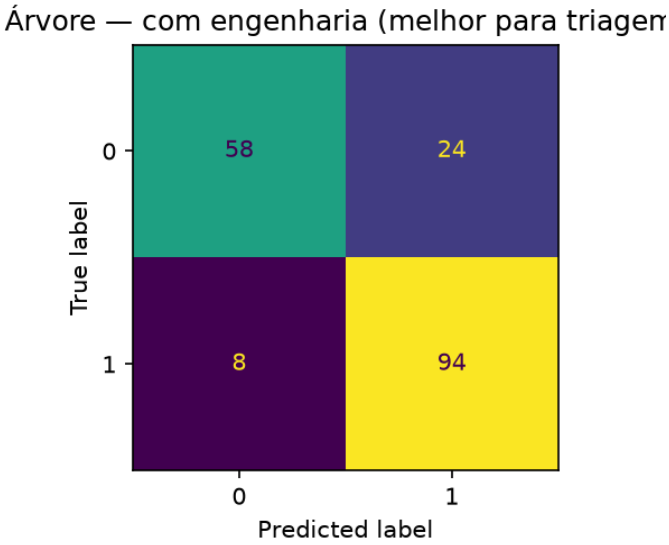
A Tabela 12 apresenta os elementos das matrizes de confusão obtidas no conjunto de teste, composto por 184 pacientes (82 da classe 0 e 102 da classe 1).

Tabela 12 – Elementos das matrizes de confusão no conjunto de teste

Modelo	TN	FP	FN (classe 1)	TP	Recall_c1	F1_c1	F1_CV
com_engenharia	58	24	**8**	94	**0,9216**	**0,8545**	0,7946
ordinal	58	24	11	91	0,8922	0,8387	**0,8604**
one-hot	70	12	21	81	0,7941	0,8308	0,8550
baseline	0	82	0	102	1,0000	0,7133	—

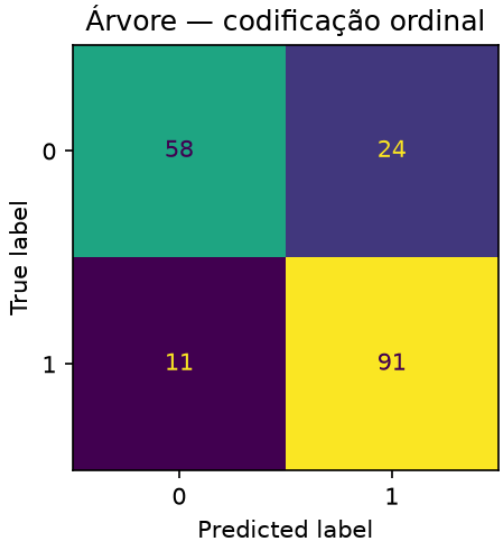
Fonte: elaborado pelos autores (2026).

Figura 1 – Matriz de confusão do modelo com engenharia de atributos (melhor resultado no teste para triagem)



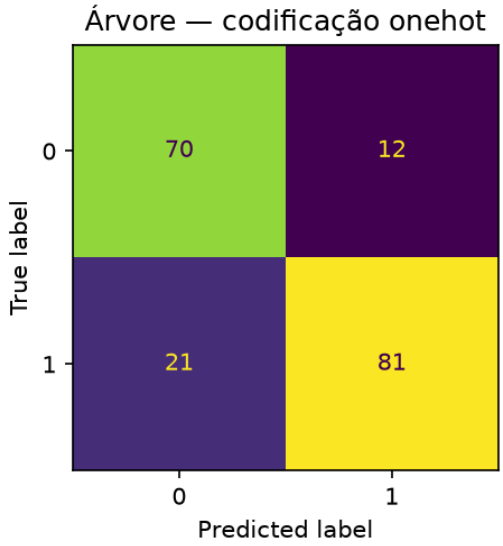
Fonte: elaborado pelos autores a partir da execução do notebook (2026).

Figura 2 – Matriz de confusão do modelo com codificação ordinal



Fonte: elaborado pelos autores a partir da execução do notebook (2026).

Figura 3 – Matriz de confusão do modelo com codificação one-hot



Fonte: elaborado pelos autores a partir da execução do notebook (2026).

O erro de maior gravidade clínica é o falso negativo da classe 1, ou seja, o paciente doente previsto como “não doente”. No conjunto de teste, o modelo *com_engenharia* é o mais adequado para triagem: apresenta 8 falsos negativos, contra 11 do ordinal e 21 do one-hot, com o mesmo número de falsos positivos (24) e o maior F1_c1 (0,8545).

Como limitação, o F1 da CV desse modelo apresentou redução (0,7946, ante 0,8604 do ordinal); logo, a melhora no teste não é confirmada pela CV e pode refletir a variância do conjunto de teste reservado. Os dois modelos mais indicados para triagem são, portanto, o *com_engenharia* e o ordinal (com 8 e 11 falsos negativos, respectivamente). A escolha entre eles envolve um compromisso entre o desempenho no teste e a robustez na CV, e exige validação externa.

4.7 Síntese das transformações e impacto nas métricas

A Tabela 13 resume as principais transformações de preparação dos dados e seus efeitos sobre as métricas, indicando melhora ou piora.

Tabela 13 – Síntese das transformações e de seu impacto nas métricas

Transformação	Antes	Depois	Efeito
Codificação one-hot → ordinal	F1_c1 0,8308	0,8387	Ganho no F1_c1 e na revocação
Imputação (mediana × moda)	—	—	Escolhida pela grade
class_weight=balanced	≈ igual	≈ igual	Sem efeito (desbalanceamento leve)
Escalonamento (*StandardScaler*)	Idêntico	Idêntico	Invariante (árvore)
Remoção de *RestingBP*/*Cholesterol*/*FastingBS*	F1_c1 0,8387	0,8272	Piora o F1_c1; melhora o F1_macro
Remoção de *ST_Slope*/*MaxHR*	F1_c1 0,8387	0,7897 / 0,7890	Piora
Engenharia de atributos	F1_c1 0,8387	0,8545 (teste)	Melhora no teste; redução na CV
Variação de hiperparâmetros one-hot (*max_depth=4*, *min_samples_leaf=10*)	F1 0,8308	0,8119	Piora

Fonte: elaborado pelos autores (2026).

5 MLflow: registro e tabulação dos experimentos

Todos os experimentos foram registrados no MLflow, no experimento *heart_failure_arvore_decisao*, com rastreamento (*tracking*) local em SQLite (*mlflow.db*) e artefatos armazenados em *mlruns/*. Ao todo, foram registradas 111 execuções (*runs*), entre execuções pai e filhas.

Cada execução armazena: (i) os parâmetros — codificação, imputação, hiperparâmetros, atributo removido, engenharia e *class_weight*; (ii) as métricas — F1, acurácia, precisão, revocação, F1 macro e IC 95%; (iii) o modelo, por meio de *mlflow.sklearn.log_model*; e (iv) os artefatos — CSVs, JSON, PNGs e ZIP. A tabela completa encontra-se em *docs/mlflow_runs.csv*,

exportada via *mlflow.search_runs*, e contém as colunas de execução, status, data, parâmetros e métricas.

As execuções principais são *arvore_onehot*, *arvore_ordinal*, *baseline_classe_majoritaria*, *ablacao_atributos* (com 12 execuções filhas), *engenharia_features* (com *sem_engenharia* e *com_engenharia*) e *relatorio_artefatos*.

6 Avaliação comparativa entre execuções

A Tabela 14 registra a evolução do experimento ao longo das execuções realizadas.

Tabela 14 – Evolução das execuções do experimento

Execução	O que mudou	Melhor F1_c1	F1_macro	Efeito
20261022_081800	Versão inicial: one-hot × ordinal + baseline	0,8387	—	Referência (somente classe 1)
20261022_083734	Inclusão da ablação com *class_weight* None/balanced	0,8387	0,8035	*balanced* ≈ *None*
20261022_090449	Ablação simplificada (sem *balanced*)	0,8387	—	Foco didático
20261022_093147	Inclusão da engenharia de atributos	0,8545 (com)	0,8192 (com)	Melhora no teste; redução na CV
20261022_094826	Variação de hiperparâmetros one-hot (*max_depth=4*, *min_samples_leaf=10*)	0,8119 (one-hot)	—	Piora no teste
20261026_075517	Métricas para as duas classes (versão final)	0,8387 (ordinal) / 0,8545 (com eng.)	0,8035 / 0,8192	Versão consolidada

Fonte: elaborado pelos autores (2026).

Da evolução das execuções, destacam-se cinco considerações. Primeiro, os hiperparâmetros escolhidos pela grade mantiveram-se estáveis (profundidade 3), exceto na variação *094826*, que piorou o desempenho no teste. Segundo, a engenharia de atributos foi a única mudança que melhorou o resultado no conjunto de teste (F1_c1 de 0,8387 para 0,8545), mas apresentou redução na CV (de 0,8604 para 0,7946), o que caracteriza um ganho não robusto. Terceiro, a ablação mostrou que remover atributos não melhora o F1_c1, apenas o F1_macro, ao custo da revocação da classe 1. Quarto, *class_weight='balanced'* não teve efeito relevante, o que é coerente com o desbalanceamento leve das classes (55/45). Por fim, a adoção de métricas para ambas as classes alterou a interpretação dos resultados: o modelo que parecia “melhor” considerando apenas a classe 1 nem sempre é o melhor em termos de F1_macro.

7 Discussão e trabalhos relacionados

A Tabela 15 relaciona os trabalhos da literatura que fundamentam as escolhas deste estudo.

Tabela 15 – Trabalhos relacionados e sua relação com este estudo

Trabalho	Contribuição	Relação com este trabalho
Qadri et al. (2023), *IEEE Access*	Técnica de engenharia de atributos (*feature engineering*) para predição de doença cardíaca	Justifica a criação de atributos derivados
Abass et al. (2025), Springer	Compara LR, SVM, KNN, DT e RF com engenharia de atributos	Reforça a engenharia como etapa do processo
Gárate-Escamilla et al. (2020), *Informatics in Medicine Unlocked*	Seleção de atributos + PCA	Compara seleção e transformação
Hasnat et al. (2025), arXiv	Engenharia de atributos + SHAP + árvores substitutas	Interpretabilidade
Page et al. (1970), *Circulation*	Idade e colesterol total como preditores de DAC	Fundamenta idade e colesterol; a razão *Chol_por_Idade* é proposta deste trabalho
Folsom et al. (2003), *Diabetes Care*	Fatores de risco para DAC	Contexto clínico
Detrano et al. (1989) / Janosi et al. (1988)	Base UCI *Heart Disease*	Origem dos dados
Fox et al. (1971)	Fórmula FCmax ≈ 220 − idade	Base de *FC_pct_teorica*

Fonte: elaborado pelos autores (2026).

As variáveis originais utilizadas nas razões (*MaxHR*, *Oldpeak*, *Cholesterol*, *RestingBP* e *ExerciseAngina*) são indicadores clínicos consolidados. As razões propostas buscam normalizar essas medidas pela idade ou pela frequência cardíaca e capturar interações (angina × depressão do segmento ST), o que auxilia a árvore a representar relações “diagonais” com menos cortes. A literatura apoia o uso de engenharia de atributos na predição de doença cardíaca, contudo, as razões específicas aqui testadas constituem hipóteses exploratórias e requerem validação externa.

Em particular, Page et al. (1970) fundamentam a idade e o colesterol total como preditores de DAC, mas não propõem a razão *Chol_por_Idade*, que é uma proposta deste trabalho. Além disso, a base do Kaggle não contém triglicerídeos e apresenta 172 registros com *Cholesterol = 0*, tratados como valores ausentes (*NaN*) e imputados dentro do *pipeline*. Como *Chol_por_Idade* depende de *Cholesterol*, esses registros também recebem imputação no atributo derivado.

Este estudo apresenta as seguintes limitações: (i) a base é pequena (918 registros) e o conjunto de teste contém apenas 184 pacientes, o que resulta em intervalos de confiança largos; (ii) utilizou-se uma única árvore, sem métodos de *ensemble* e sem validação externa; (iii) a

engenharia de atributos melhorou o desempenho no conjunto de teste, mas apresentou redução na CV, de modo que o ganho não é conclusivo; e (iv) não foram testados o ajuste de limiar de decisão, a técnica SMOTE (*Synthetic Minority Over-sampling Technique*) nem outros modelos.

8 Conclusão e recomendações

No conjunto de teste, o melhor modelo para triagem foi o *com_engenharia* (codificação ordinal acrescida de cinco atributos derivados), com 8 falsos negativos, revocação da classe 1 (*recall_c1*) de 0,9216 e F1_c1 de 0,8545, mantendo o mesmo número de falsos positivos (24) do modelo ordinal. Por outro lado, o modelo mais robusto na validação cruzada foi o ordinal sem engenharia, com F1_CV de 0,8604, ante 0,7946 do *com_engenharia*.

A engenharia de atributos melhorou o desempenho no conjunto de teste, mas não teve o ganho confirmado pela CV, devendo ser tratada como promissora, porém não conclusiva. Quanto à ablação, a manutenção de todos os atributos maximiza o F1_c1, ao passo que a remoção de *RestingBP*, *Cholesterol* ou *FastingBS* melhora o F1_macro, mas aumenta o risco de falso negativo da classe 1.

Como recomendação clínica, sugere-se, para fins de triagem, priorizar a revocação e o F1 da classe 1, adotando o *com_engenharia* com base no desempenho no teste e o ordinal como alternativa com maior segurança nos testes. Deve-se avaliar o ajuste do limiar de decisão e validar o modelo em base externa antes de qualquer uso real. Por fim, as 111 execuções registradas no MLflow permitem reproduzir e comparar todos os experimentos realizados.

Referências

[1] FEDESORIANO. **Heart Failure Prediction Dataset**. Kaggle, 2021. Disponível em: https://www.kaggle.com/datasets/fedesoriano/heart-failure-prediction.

[2] DETRANO, R. et al. International application of a new probability algorithm for the diagnosis of coronary artery disease. **American Journal of Cardiology**, 1989.

[3] JANOSI, A.; STEINBRUNN, W.; PFISTERER, M.; DETRANO, R. **Heart Disease**. UCI Machine Learning Repository, 1988.

[4] QADRI, A. M. et al. Effective Feature Engineering Technique for Heart Disease Prediction With Machine Learning. **IEEE Access**, 2023.

[5] ABASS, A.; BATHLA, G.; WASSON, V. Heart Disease Prediction Using Machine Learning with Feature Engineering. In: Soft Computing and Signal Processing (ICSCSP 2024). **Lecture Notes in Networks and Systems**, v. 1221. Springer, 2025, p. 697–709. DOI: https://doi.org/10.1007/978-981-96-0924-6_55.

[6] GÁRATE-ESCAMILLA, A. K.; HAJJAM EL HASSANI, A.; ANDRÈS, E. Classification models for heart disease prediction using feature selection and PCA. **Informatics in Medicine Unlocked**, 2020.

[7] HASNAT, M. A. et al. Interpretable Heart Disease Prediction via a Weighted Ensemble Model. **arXiv:2511.01947**, 2025.

[8] PAGE, I. H. et al. Prediction of Coronary Heart Disease Based on Clinical Suspicion, Age, Total Cholesterol, and Triglyceride. **Circulation**, v. 42, n. 4, p. 625–645, 1970. DOI: https://doi.org/10.1161/01.cir.42.4.625.

[9] FOLSOM, A. R. et al. Prediction of Coronary Heart Disease in Middle-Aged Adults With Diabetes. **Diabetes Care**, 2003.

[10] FOX, S. M.; NAUGHTON, J. P.; HASKELL, W. L. Physical activity and the prevention of coronary heart disease. **Annals of Clinical Research**, 1971.